

# Modélisation de l'utilisateur dans des environnements multimodaux

Amel Yessad

Septembre 2025

# Pourquoi modéliser l'utilisateur ?

- Interaction adaptative (assistants, systèmes éducatifs, agents).
- Multimodalité : voix, gestes, visage, signaux physiologiques.
- Gestion de l'incertitude : bruit, ambiguïté, variabilité.
- Exemples : robotique médicale, assistants intelligents, interfaces gestuelles

- **Variables observables** : mesures directes (voix, gaze, geste)
- **Variables latentes** : états cachés (intention, attention)
- **Bruit** : erreurs de mesure
- **Incertitude** : probabilité que l'état réel corresponde à l'observation

# Bruit vs Incertitude

- **Bruit (Noise) :**

- Perturbation aléatoire dans les données observées.
- Origine : capteurs, environnement, erreurs de mesure.
- Exemple : micro avec bruit de fond → ex. mesures MFCC altérés.

- **Incertainitude (Uncertainty) :**

- Ambiguïté dans l'interprétation de l'état réel de l'utilisateur.
- Manque de confiance dans l'interprétation/inférences
- Liée au modèle, pas seulement aux données
- Origine : complexité humaine, variabilité inter-individuelle, contexte.
- Exemple : même expression faciale = peur *ou* surprise, geste ambigu = sélectionner *ou* zoomer, réussir un exercice = maîtrise *ou* guess

- **Synthèse :**

- Bruit = problème dans le **signal observé**.
- Incertitude = problème dans la **signification** ou la **décision**.
- Solutions : pré-traitement pour le bruit, modèles probabilistes pour l'incertitude.

- Réseaux bayésiens pour modéliser des liens de causalité entre variables :  
 $P(I|G, V) \propto P(G|I)P(V|I)P(I)$  ( $\propto$  signifie proportionnel à)
  - $I$  : l'état interne de l'utilisateur (caché) — par exemple l'émotion ou l'intention.
  - $G$  : un indice observable gestuel (gestes, expressions corporelles, postures).
  - $V$  : un indice observable vocal (prosodie, intensité de la voix, rythme).
- HMM (Hidden Markov Model) pour suivre l'évolution temporelle des états cachés

- Modélisation des relations causales entre signaux et états latents de l'utilisateur.
- Exemple : [intonation, fréquence cardiaque, visage] → état émotionnel.
- Gestion probabiliste de l'incertitude.
- Extension : réseaux bayésiens dynamiques (DBN).

# Réseaux bayésiens : inférence

- **Structure du graphe :**

$$I \rightarrow G, \quad I \rightarrow V$$

où  $I$  = état interne (caché),  $G$  = indice gestuel,  $V$  = indice vocal.

- **Factorisation de la loi jointe :**

$$P(I, G, V) = P(I) P(G|I) P(V|I)$$

- **Inférence (posterior) :**

$$P(I|G, V) = \frac{P(G|I) P(V|I) P(I)}{P(G, V)}$$


avec  $P(G, V)$  facteur de normalisation.

- Souvent on écrit :

$$P(I|G, V) \propto P(G|I) P(V|I) P(I)$$

pour indiquer la relation proportionnelle.

## Exemple : Bayes naïf pour modéliser les émotions



- Fusionner des observations pour estimer un état latent ou caché
- Permet d'intégrer plusieurs signaux avec incertitude
- Classifieur (apprentissage supervisé) : relie des variables explicatives (features) à une classe (état latent)
- Cas simple des réseaux bayésiens, les features sont conditionnellement indépendantes sachant la classe



# Exemple : Bayes naïf pour modéliser les émotions

## Variables observables :

- Voix : calme / tendue
- Visage : sourire / froncement

## Variables latentes :

- Émotion : {Content, Stressé}

## Probabilités conditionnelles (extraites/simulées) :

$$P(\text{Voix}=\text{calme} \mid \text{Content}) = 0.8 \quad P(\text{Visage}=\text{sourire} \mid \text{Content}) = 0.9$$

$$P(\text{Voix}=\text{tendue} \mid \text{Stress}) = 0.7 \quad P(\text{Visage}=\text{fronce} \mid \text{Stress}) = 0.8$$

## Probabilités marginales :

$$P(\text{Émotion} = \text{Content}) = 0.5 \quad P(\text{Émotion} = \text{Stressé}) = 0.5$$

## Probabilité conjointe avec hypothèse d'indépendance conditionnelle :

$$P(\text{Voix}, \text{Visage}, \text{Émotion}) = P(\text{Voix} \mid \text{Émotion}) P(\text{Visage} \mid \text{Émotion}) P(\text{Émotion})$$

## Cas 1 : cohérent (Voix=calme, Visage=sourire)

### Probabilité conjointe :

$$\begin{aligned} P(\text{calme, sourire, Content}) &= P(\text{calme} \mid \text{Content}) P(\text{sourire} \mid \text{Content}) P(\text{Content}) \\ &= 0.8 \times 0.9 \times 0.5 = 0.36 \end{aligned}$$

### De manière similaire :

$$P(\text{calme, sourire, Stress}) = 0.3 \times 0.2 \times 0.5 = 0.03$$

### Ce qui donne :

$$P(\text{Content} \mid \text{calme, sourire}) = \frac{0.36}{0.39} \approx 0.923$$

$$P(\text{Stressé} \mid \text{calme, sourire}) = \frac{0.03}{0.39} \approx 0.077$$

**Conclusion** : forte confiance pour **Content**.

## Cas 2 : contradictoire (Voix=tendue, Visage=sourire)

**Probabilité conjointe :**

$$P(\text{tendue, sourire, Content}) = 0.2 \times 0.9 \times 0.5 = 0.09$$

$$P(\text{tendue, sourire, Stressé}) = 0.7 \times 0.2 \times 0.5 = 0.07$$


**Puis :**

$$P(\text{Content} \mid \text{Obs}) = \frac{0.09}{0.16} = 0.5625$$

$$P(\text{Stressé} \mid \text{Obs}) = \frac{0.07}{0.16} = 0.4375$$

**Conclusion :** probabilités proches  $\Rightarrow$  **forte incertitude.**

# Visualisation de l'incertitude



# Modèles de Markov cachés (HMM)

- États latents = états affectifs (Stress, Relax).
- Transitions probabilistes entre états.
- Observations multimodales (signaux physiologiques).

# Exemple HMM : Détection de stress

Considérons un HMM avec deux états cachés :

- $S$  : Stress
- $R$  : Relax

Matrice de transition :

$$A = \begin{bmatrix} P(S \rightarrow S) & P(S \rightarrow R) \\ P(R \rightarrow S) & P(R \rightarrow R) \end{bmatrix} = \begin{bmatrix} 0.7 & 0.3 \\ 0.4 & 0.6 \end{bmatrix}$$

Matrice d'émission (observations = rythme cardiaque Haut (H) ou Bas (B)) :

$$B = \begin{bmatrix} P(H|S) & P(B|S) \\ P(H|R) & P(B|R) \end{bmatrix} = \begin{bmatrix} 0.8 & 0.2 \\ 0.3 & 0.7 \end{bmatrix}$$

# HMM : Observations vs États cachés

- **États cachés** : ce que l'on veut inférer.
  - $S$  = Stress
  - $R$  = Relax
- **Observations** : signaux mesurables (indices visibles)
  - $H$  = Rythme cardiaque haut
  - $B$  = Rythme cardiaque bas
- Exemple de séquence observée :  $O = (H, H, B)$ 
  - $t=1$  :  $H$
  - $t=2$  :  $H$
  - $t=3$  :  $B$
- **Principe du HMM** :  
Observations visibles  $\Rightarrow$  inférence des états cachés via matrice d'émission  $P(O_t|S_t)$ .
- Probabilités d'émission :
  - $P(H|S) = 0.8, P(B|S) = 0.2$
  - $P(H|R) = 0.3, P(B|R) = 0.7$

# Inférence avec l'algorithme de Viterbi

Observation :  $O = (H, H, B, B, B, H, H....)$ .

❶ Initialisation :

$$\delta_1(S) = P(S)P(H|S), \quad \delta_1(R) = P(R)P(H|R)$$

❷ Récurrence :

$$\delta_t(j) = \max_i [\delta_{t-1}(i)a_{ij}]b_j(O_t)$$

où  $a_{ij}$  = proba de transition  $i \rightarrow j$ ,  $b_j(O_t)$  = proba d'observer  $O_t$  depuis l'état  $j$  et  $\delta_t(j)$  la probabilité du chemin le plus probable d'états sur  $t$  pas de temps

❸ Terminaison :

$$P^* = \max_j \delta_T(j)$$

et on retrouve la séquence d'états la plus probable.



# Algorithme de Viterbi : exemple simple

Considérons un HMM avec deux états cachés :

- $S$  : Stress
- $R$  : Relax

Matrice de transition :

$$A = \begin{bmatrix} 0.7 & 0.3 \\ 0.4 & 0.6 \end{bmatrix}$$

Matrice d'émission (observations = Haut (H), Bas (B)) :

$$B = \begin{bmatrix} P(H|S) = 0.8 & P(B|S) = 0.2 \\ P(H|R) = 0.3 & P(B|R) = 0.7 \end{bmatrix}$$

Probabilités initiales :  $P(S) = 0.6$ ,  $P(R) = 0.4$ .

# Étape 1 : Initialisation

Observation  $O = (H, H, B)$ .

$$\delta_1(S) = P(S) \cdot P(H|S) = 0.6 \times 0.8 = 0.48$$

$$\delta_1(R) = P(R) \cdot P(H|R) = 0.4 \times 0.3 = 0.12$$

## Étape 2 : Récurrence (t=2)

$$\begin{aligned}\delta_2(S) &= \max [\delta_1(S) \cdot a_{SS}, \delta_1(R) \cdot a_{RS}] \cdot P(H|S) \\ &= \max[0.48 \times 0.7, 0.12 \times 0.4] \times 0.8 = 0.2688\end{aligned}$$

$$\begin{aligned}\delta_2(R) &= \max [\delta_1(S) \cdot a_{SR}, \delta_1(R) \cdot a_{RR}] \cdot P(H|R) \\ &= \max[0.48 \times 0.3, 0.12 \times 0.6] \times 0.3 = 0.0432\end{aligned}$$

## Étape 3 : Récurrence (t=3)

Observation  $O_3 = B$ .

$$\delta_3(S) = \max[0.2688 \times 0.7, 0.0432 \times 0.4] \times P(B|S) = 0.0376$$

$$\delta_3(R) = \max[0.2688 \times 0.3, 0.0432 \times 0.6] \times P(B|R) = 0.0564$$

## Étape 4 : Terminaison et chemin optimal

$$P^* = \max(\delta_3(S), \delta_3(R)) = \max(0.0376, 0.0564) = 0.0564$$

$\Rightarrow$  La séquence d'états la plus probable est  $(S, S, R)$ .

# Différence entre HMM et Réseau bayésien

| Réseau bayésien                                               | HMM                                                       |
|---------------------------------------------------------------|-----------------------------------------------------------|
| Graphe orienté acyclique (DAG).                               | Cas particulier de réseau bayésien dynamique.             |
| Relations causales/statistiques entre variables.              | États cachés évoluant dans le temps.                      |
| Peut être statique.                                           | Conçu pour des séquences temporelles.                     |
| Inférence : propagation de croyances.                         | Inférence : Forward-Backward, Viterbi.                    |
| Exemple : déduire une émotion à partir de signaux simultanés. | Exemple : suivre l'évolution d'une émotion dans le temps. |

# Types d'inférences dans un réseau bayésien

## 1. Inférence diagnostique (bottom-up)

Déduire la cause probable à partir des observations :

$$P(\text{Cause} \mid \text{Observations})$$

Exemple : observer des gestes et la voix  $\rightarrow$  inférer l'état émotionnel de l'utilisateur.

## 2. Inférence prédictive (top-down)

Déduire la probabilité d'observations futures à partir d'un état latent :

$$P(\text{Observation} \mid \text{Cause})$$

Exemple : connaître l'intention  $\rightarrow$  prédire le geste probable.

## 3. Inférence intercausale (explaining away)

Relation entre causes possibles d'un même effet observé :

$$P(\text{Cause}_1 \mid \text{Observation}, \text{Cause}_2)$$

Exemple : un sourire peut être causé par la joie ou la politesse ; l'une réduit la probabilité de l'autre.

*Remarque : Les réseaux bayésiens permettent de gérer l'incertitude et les relations causales entre variables.*

# Types d'inférences dans un HMM

## 1. Évaluation (Forward / Backward)

Calcul de la probabilité d'une séquence observée :

$$P(O|\lambda) = P(o_1, o_2, \dots, o_T | \lambda)$$

Sert à mesurer la vraisemblance du modèle par rapport aux observations.

## 2. Décodage (Viterbi)

Recherche de la séquence d'états cachés la plus probable :

$$q_{1:T}^* = \arg \max_{q_{1:T}} P(q_{1:T} | O, \lambda)$$

Permet de reconstruire l'évolution temporelle des états latents.

## 3. Inférence de croyances (Smoothing)

Estimation de la probabilité d'un état à un instant donné :

$$P(q_t | O, \lambda)$$

Fournit une estimation probabiliste plutôt qu'un chemin unique.



- **CNN (Convolutional Neural Networks) :**

- Capturent des motifs visuels locaux.
- Application : reconnaissance d'expressions faciales, micro-expressions, postures.

- **RNN / LSTM (Recurrent Neural Networks) :**

- Exploitent la dépendance temporelle dans les séquences.
- Application : analyse de la prosodie vocale, signaux EEG/ECG, gestes séquentiels.

- **Transformers multimodaux :**

- Mécanisme d'attention pour pondérer les modalités.
- Application : fusion texte-audio-vision pour estimer l'émotion ou l'intention.

- **Réseaux neuronaux bayésiens :**

- Intègrent l'incertitude directement dans les poids ou l'espace latent.
- Application : modéliser des états internes avec estimation de confiance.

# Évaluation des modèles probabilistes de l'utilisateur

## 1. Modèles supervisés (Naïve Bayes, réseaux bayésiens)

- Matrice de confusion
- Accuracy, précision, rappel, F1-score
- Log-likelihood
- Validation croisée / train-test split

## 2. Modèles séquentiels (HMM)

- Décodage (Viterbi) : accuracy par état, F1-score
- Évaluation de séquence : log-likelihood  $P(O|\lambda)$
- Inférence de croyances : comparaison  $P(q_t|O, \lambda)$  vs état réel (KL divergence, cross-entropy)
- Apprentissage non supervisé : likelihood sur jeu de test, visualisation des séquences générées

## 3. Méthodes complémentaires : courbes ROC / AUC, simulation d'utilisateurs, analyse qualitative des états et transitions

- Tuteur intelligent : adaptation des activités selon engagement de l'élève.
- Interface voiture : adaptation de l'assistance selon le stress/fatigue du conducteur.
- Jeux sérieux : adaptation de narration/difficulté aux performances du joueur.

# Modélisation de l'apprenant avec le Bayesian Knowledge Tracing (BKT)


**Objectif** : suivre la maîtrise d'une compétence par un apprenant au fil du temps [Corbett et Anderson, 1994].

**Contexte** : tuteur intelligent ou adaptive learning

**Principe** : modéliser la probabilité que l'apprenant maîtrise une compétence  $K_t$  à chaque essai  $t$ , à partir de ses réponses  $O_t$  (correcte / incorrecte).


**Variables principales** :

- $K_t$  : état latent – l'apprenant maîtrise ou non la compétence
- $O_t$  : observation – réponse correcte ou incorrecte
- $L_0$  : probabilité initiale de maîtrise la compétence
- $T$  : probabilité de transition (apprentissage entre essais)
- $G$  : probabilité de "guess" (réponse correcte sans maîtriser)
- $S$  : probabilité de "slip" (erreur malgré maîtrise)



**Le modèle BKT [Pardos et Hefferman, 2011]**

# Modèle et équations



**Modèle :** HMM simple avec états cachés  $K_t$  et observations  $O_t$ .

**Mise à jour de la probabilité de maîtrise après observation  $O_t$  :**

**Si  $O_t = \text{Correct}(1)$  :**

$$P(K_t = 1 \mid O_t = 1) = \frac{P(K_{t-1} = 1)(1 - S)}{P(K_{t-1} = 1)(1 - S) + P(K_{t-1} = 0)G}$$

**Si  $O_t = \text{Incorrect}(0)$  :**

$$P(K_t = 1 \mid O_t = 0) = \frac{P(K_{t-1} = 1)S}{P(K_{t-1} = 1)S + P(K_{t-1} = 0)(1 - G)}$$

**Diagnostic / Prédiction pour le prochain essai :**

$$P(K_{t+1} = 1) = P(K_t = 1 \mid O_t) + (1 - P(K_t = 1 \mid O_t))T$$

# Exemple illustratif

**Données** : séquence d'observations sur un apprenant : Correct / Incorrect / Correct.

**Paramètres (hypothétiques) du BKT** :

- $L_0 = 0.2, T = 0.3, G = 0.2, S = 0.1$

**Étapes** :

- 1 Initialisation :  $P(K_1 = 1) = L_0 = 0.2$
- 2 Observation 1 (Correct) : mise à jour via formule BKT  $\rightarrow P(K_1|O_1)$
- 3 Prévission essai 2 :  $P(K_2) = P(K_1|O_1) + (1 - P(K_1|O_1))T$
- 4 Répéter pour tous les essais

**Résultat** : estimation dynamique de la maîtrise après chaque essai.

# Exemple de calcul de probabilité dans BKT (1)

Paramètres :

$$L_0 = 0.2, \quad T = 0.3, \quad G = 0.2, \quad S = 0.1$$

Séquence d'observations : Correct ( $O_1=1$ ), Incorrect ( $O_2=0$ ), Correct ( $O_3=1$ )

Étape 1 : initialisation

$$P(K_1 = 1) = L_0 = 0.2$$

Étape 2 : mise à jour après observation 1 (Correct)

$$P(K_1 = 1 \mid O_1 = 1) = \frac{P(K_1 = 1)(1 - S)}{P(K_1 = 1)(1 - S) + P(K_1 = 0)G}$$

Calcul :

$$\frac{0.2 \cdot 0.9}{0.2 \cdot 0.9 + 0.8 \cdot 0.2} = \frac{0.18}{0.18 + 0.16} \approx 0.529$$

Étape 3 : prédiction pour l'essai 2

$$P(K_2 = 1) = P(K_1 = 1 \mid O_1) + (1 - P(K_1 = 1 \mid O_1))T$$

$$P(K_2 = 1) = 0.529 + (1 - 0.529) \cdot 0.3 \approx 0.688$$

## Étape 4 : mise à jour après observation 2 (Incorrect)

$$P(K_2 = 1 \mid O_2 = 0) = \frac{P(K_2 = 1) \cdot S}{P(K_2 = 1) \cdot S + P(K_2 = 0) \cdot (1 - G)}$$

Calcul :

$$\frac{0.688 \cdot 0.1}{0.688 \cdot 0.1 + 0.312 \cdot 0.8} \approx \frac{0.0688}{0.0688 + 0.2496} \approx 0.216$$

Et ainsi de suite pour les étapes suivantes...



# Avantages et limites du BKT

## Avantages :

- Simple, interprétable, facile à implémenter
- Permet prédiction personnalisée pour chaque apprenant
- Base pour adaptative learning systems

## Limites :

- Hypothèse forte : compétence binaire (maîtrisée / non maîtrisée)
- Pas de dépendance entre compétences différentes
- Paramètres globaux souvent partagés entre apprenants

- Russell, S., Norvig, P., & Intelligence, A. (1995). A modern approach. Artificial Intelligence. Prentice-Hall, Englewood Cliffs, 25(27), 79-80.
- Bishop, C. M., & Nasrabadi, N. M. (2006). Pattern recognition and machine learning (Vol. 4, No. 4, p. 738). New York : springer.
- Baltrušaitis, T., Ahuja, C., & Morency, L. P. (2018). Multimodal machine learning : A survey and taxonomy. IEEE transactions on pattern analysis and machine intelligence, 41(2), 423-443.
- Corbett, A. T., & Anderson, J. R. (1994). Knowledge tracing : Modeling the acquisition of procedural knowledge. User modeling and user-adapted interaction, 4(4), 253-278.
- Pardos, Z. A., & Heffernan, N. T. (2011, July). KT-IDEM : Introducing item difficulty to the knowledge tracing model. In International conference on user modeling, adaptation, and personalization (pp. 243-254). Berlin, Heidelberg : Springer Berlin Heidelberg.