

Données textuelles et cas d'usage

François Bouchet - LIP6 / Sorbonne Université

Cours AI-ADAPT | Master AI2D

1er décembre 2025

Objectifs de la session

- Comprendre ce que le texte **révèle** de l'utilisateur (et ce qu'il cache)
- Maîtriser les **niveaux d'analyse** : du mot au discours
- Distinguer approches **interprétables** vs **boîte noire**
- Construire un **pipeline** d'extraction de features textuelles
- Identifier les **cas d'usage** pertinents pour l'adaptation

Plan de la session

Partie 1 : Fondements (2h)

- ① Le texte comme fenêtre sur l'utilisateur
- ② Niveaux d'analyse linguistique
- ③ Des indices aux features exploitables
- ④ Positionnement des LLMs

: Pause 15 min :

Partie 2 : Applications (2h)

- ⑤ Pipeline technique
- ⑥ Cas d'usage adaptatifs
- ⑦ Enjeux et limites
- ⑧ Travaux pratiques

PARTIE 1 : FONDEMENTS

Texte vs autres modalités

Modalité	Nature du signal	Contrôle utilisateur	Richesse sémantique
Physiologique	Involontaire	Nul	Faible
Oculométrique	Semi-conscient	Partiel	Moyenne
Haptique	Intentionnel	Élevé	Contextuelle
Textuel	Intentionnel	Élevé	Très élevée

Ce que le texte peut révéler

État cognitif

- Niveau de connaissance → vocabulaire technique, précision
- Incertitude épistémique → marqueurs d'hésitation
- Charge cognitive → complexité syntaxique, erreurs

État affectif

- Frustration, confusion → lexique émotionnel, ponctuation
- Engagement → longueur, élaboration des réponses

Intentions

- Demande d'aide vs exploration autonome
- Abandon vs persévérance

L'utilisateur contrôle ce qu'il écrit...

...mais pas *comment* il l'écrit

- **Contenu** → choix conscient, potentiellement stratégique
- **Style** → largement automatique, difficile à contrôler

"Function words are the fingerprints of language" (Pennebaker, Mehl et Niederhoffer 2003)

Temporalité du texte en dialogue


Signaux temporels exploitables

- Délai avant réponse → réflexion, hésitation, désengagement ?
- Rythme d'écriture (si disponible) → charge cognitive
- Patterns d'édition → incertitude, perfectionnisme
- Processus de révision (Nebel et al. [2025](#))


Attention : interprétation très contextuelle

- Délai long = réflexion approfondie OU distraction externe ?
- Réponse rapide = facilité OU impulsivité ?

**Comment passer d'une trace textuelle brute
à une représentation actionnable
de l'état de l'utilisateur
pour l'adaptation ?**



Les couches du texte



Chaque niveau → types d'information différents

Token : selon contexte, peut désigner un mot (NLP classique) ou un sous-mot (LLMs)

Niveau lexical

Ce qu'on observe

- Choix de vocabulaire (technique vs courant)
- Mots fonctionnels (pronoms, articles, prépositions)
- Marqueurs d'incertitude : "*peut-être*", "*je pense que*", "*il me semble*"
- Marqueurs émotionnels : lexique affectif

Outils

Dictionnaires, comptages, lexiques annotés ([LIWC^a](#), [ANEW^b](#))

a. Multilingue dont français

b. 1000+ mots anglais annotés en termes de pleasure, arousal, dominance

Avantage :

Simple, interprétable, rapide

Limite :

Ignore le contexte, sensible aux synonymes

Focus : les mots fonctionnels

Catégorie	Exemples	Ce que ça révèle
Pronoms 1ère pers.	je, me, moi	Auto-focus, dépression (↑), statut social (↓)
Pronoms 2ème pers.	tu, vous	Orientation vers l'autre
Articles	le, un	Pensée concrète vs abstraite
Prépositions	dans, sur	Complexité cognitive
Négations	ne...pas, jamais	Conflit, anxiété

(Tausczik et Pennebaker 2010)

Niveau syntaxique

Ce qu'on observe

- Longueur des phrases
- Complexité (subordination, enchâssements)
- Structure des questions (fermées vs ouvertes)
- Phrases incomplètes, reformulations

Mesures simples

- Nb moyen de mots par phrase
- Ratio propositions principales/subordonnées
- Présence de marqueurs interrogatifs

Utilité pour l'adaptation

- Phrases courtes + simples → difficulté ? fatigue ?
- Questions directes → besoin d'aide explicite

Niveau discursif : les actes de dialogue

Définition (Austin 1962; Searle 1969)

Un énoncé ne décrit pas seulement le monde, il **accomplit une action**

Taxonomie classique (Searle)

- **Assertifs** : affirmer, informer, décrire
- **Directifs** : demander, ordonner, suggérer
- **Commissifs** : promettre, s'engager
- **Expressifs** : remercier, s'excuser, se plaindre
- **Déclaratifs** : nommer, condamner (actes institutionnels)

Distinction importante

- **Acte de langage** (Speech Act) → niveau philosophique/linguistique
- **Acte de dialogue** (Dialogue Act) → opérationnalisation pour le traitement automatique

Évolution historique

- ① Austin/Searle (1960-70) → fondements théoriques
- ② Conversation Analysis (1970-80) → tours de parole, adjacence
- ③ DAMSL, Switchboard (1990-2000) → annotation computationnelle
- ④ ISO 24617-2 (2012) → standardisation internationale

DAMSL : Dialogue Act Markup in Several Layers

Principes (Core et Allen 1997)

- Annotation **multi-dimensionnelle** : un tour peut avoir plusieurs fonctions
- Distinction **Forward-looking** / **Backward-looking**

Dimension	Forward-looking	Backward-looking
Fonction	Ce que le tour attend comme suite	Comment le tour répond au précédent
Exemples	Question, Requête, Suggestion	Réponse, Accord, Refus, Acknowledgement

Intérêt pour les agents : modéliser les *obligations conversationnelles*

- Une question crée une attente de réponse
- Un non-respect de cette attente = signal (confusion ? désengagement ?)

Switchboard-DAMSL : le benchmark historique

Corpus (Stolcke et al. 2000)

- 1 155 conversations téléphoniques
- 205 000 énoncés annotés
- 42 labels d'actes de dialogue

Résultats de référence

- Accuracy machine : **71%**
- Accord inter-annotateurs (plafond humain) : **84%**

Table – Évolution de la classification (42 classes)

Modèle	Année	Accuracy
Baseline (chance)	—	35%
HMM + n-gram (Stolcke et al. 2000)	2000	71%
RNN (Lee et Derroncourt 2016)	2016	73.1%
Bi-LSTM-CRF (Kumar et al. 2018)	2018	79.2%
SGNN (Ravi et Kozareva 2018)	2018	83.1%
CASA (Raheja et Tetreault 2019)	2019	82.9%
<i>Accord inter-annotateur humain</i>	2000	84%

9 dimensions fonctionnelles (Bunt et al. 2012)

Dimension	Exemples de fonctions
Task	Inform, Question, Request, Suggest
Auto-Feedback	Auto-Positive, Auto-Negative
Allo-Feedback	Allo-Positive, Allo-Negative
Turn Management	Turn-Take, Turn-Keep, Turn-Release
Time Management	Stalling, Pausing
Discourse Structuring	Opening, Closing, Topic-Shift
Social Obligations	Greeting, Apology, Thanking
...	...

Lien avec les SMA (Systèmes Multi-Agents)

Les actes de dialogue sont des **actes de communication** au sens des SMA

- FIPA-ACL (Foundation for Intelligent Physical Agents) s'inspire directement de Searle
- Performatifs : INFORM, REQUEST, CONFIRM, PROPOSE, ACCEPT...

Architecture typique d'un agent conversationnel

Entrée texte

- Classification acte de dialogue
- Mise à jour état du dialogue
- Sélection acte de réponse
- Génération texte

Pourquoi c'est utile pour l'adaptation

Pattern observé	Interprétation possible	Adaptation suggérée
Question → Question → Question	Difficulté, besoin de clarification	Augmenter le support, simplifier
Assertion → Élaboration → Question précise	Engagement, maîtrise partielle	Complexifier, approfondir
Réponse courte → Acknowledgement minimal	Désengagement ? Fatigue ?	Vérifier, proposer pause
Désaccord → Contre-argumentation	Pensée critique active	Encourager, débattre

Exemple annoté détaillé

Tour	Texte	Acte (Task)	Acte (Feedback)	Signal
U1	"Je ne comprends pas trop la différence entre X et Y"	Inform (incertitude)	:	Confusion explicite
S1	"La différence principale est que X fait A tandis que Y fait B"	Inform	:	:
U2	"Ah d'accord"	:	Allo-Positive	Acknowledgement
U3	"Mais du coup pour Z, c'est X ou Y qu'il faut utiliser?"	Question	:	Besoin de précision
S2	"Pour Z, je recommande Y parce que..."	Answer + Inform	:	:
U4	"Ok ok"	:	Allo-Positive (×2)	Confirmation, peut-être hâtive

Comment transformer "l'utilisateur semble incertain"
en **valeur numérique** ?

Deux grandes approches

① Dictionnaires / Règles

- Listes de mots prédéfinies
- Comptage et normalisation
- Ex : LIWC, lexiques de sentiment

② Apprentissage supervisé

- Corpus annoté (coûteux)
- Modèle entraîné
- Ex : classifieur de sentiment, détecteur d'émotion

Linguistic Inquiry and Word Count (Pennebaker, Francis et Booth 2001; Boyd et al. 2022)

- ~ 80 catégories psychologiquement motivées
- Comptage de mots → % par catégorie
- Validé sur de nombreuses études empiriques

Catégories utiles pour la modélisation utilisateur

- Cognitive processes : *cause, know, think...*
- Certainty : *always, never* vs Tentativeness : *maybe, perhaps*
- Affective processes : positive emotion, negative emotion

Forces

- Interprétable : on sait exactement ce qu'on mesure
- Rapide : simple comptage
- Pas d'entraînement nécessaire
- Validité empirique établie

Limites

- Ignore le contexte : "pas content" vs "pas mal"
- Rigide : mots hors dictionnaire ignorés
- Dépendant du domaine / de la langue
- Pas de désambiguïsation (polysémie)

Au-delà du comptage : marqueurs de hedging

Hedging

Stratégie linguistique pour atténuer l'engagement (Hyland 1996; Hyland 1998)

Types de hedges

- **Épistémiques** : *peut-être, il semble que, probablement*
- **Approximateurs** : *environ, à peu près, quelque chose comme*
- **Boucliers** : *selon moi, d'après X, on pourrait dire*

Application : détecter l'incertitude épistémique de l'utilisateur

- Haute fréquence de hedges → doute sur ses propres connaissances
- Utile pour adapter le niveau d'explication

Approche par apprentissage supervisé

Principe

- ➊ Corpus de textes annotés (état utilisateur connu)
- ➋ Extraction de features (lexicales, syntaxiques, sémantiques)
- ➌ Entraînement d'un classifieur
- ➍ Application sur nouveaux textes

Avantages

- Peut capturer des patterns complexes
- S'adapte au domaine si données disponibles

Inconvénients

- Nécessite des annotations (coût, biais)
- Moins interprétable (surtout modèles complexes)
- Risque de sur-apprentissage

Embeddings : représentations denses

Idée : représenter les mots/phrases comme vecteurs dans un espace continu

- **Word2Vec, GloVe** : vecteurs par mot
- **BERT, Sentence-BERT** : vecteurs contextuels
- Exemple classique : $\text{roi} + \text{femme} = \text{reine}$

Ce qu'on gagne

- Similarité sémantique (synonymes proches)
- Capture du contexte (polysémie)

Ce qu'on perd

- Interprétabilité directe
- Dimensions sans signification intuitive

Comparaison des approches

Critère	Dictionnaire	ML classique	Embeddings/DL
Interprétabilité	✓✓✓	✓✓	✓
Données requises	Lexique	Corpus annoté	(Pré)entraînement
Adaptabilité domaine	Manuelle	Automatique	Transfer learning
Gestion contexte	✗	Partielle	✓✓

(Van Atteveldt et al. [2021](#))

Ce que les LLMs changent

Capacités nouvelles

- Zero-shot / few-shot classification
- Raisonnement en langage naturel
- Génération de feedback personnalisé
- Compréhension contextuelle profonde

Exemple de prompt

Analyse le message suivant et indique :

- * L'état émotionnel probable (frustré/neutre/engagé)
- * Le niveau de certitude (faible/moyen/élevé)
- * L'intention principale (demande d'aide/exploration/abandon)

Message : "Bon, j'ai essayé ce que tu as dit mais ça marche toujours pas, je comprends vraiment pas pourquoi..."

Ce que les LLMs ne changent pas

Problèmes persistants

- **Boîte noire** : pourquoi cette classification ?
- **Hallucinations** : confiance $\neq$ fiabilité
- **Latence** : 500ms-2s par requête API
- **Coût** : XX € par million de tokens
- **Dépendance** : service externe, disponibilité, vie privée

Pour l'adaptation temps réel

- Seuil de latence acceptable $\sim$ 200-500ms
- Incompatible avec appel API à chaque tour

Le problème de la calibration

Définition

Un modèle est calibré si sa confiance reflète sa fiabilité

"Je suis sûr à 80%" → devrait être correct 80% du temps

Constat (Guo et al. 2017)

- Les réseaux de neurones modernes sont **sur-confiants**
- Un modèle à 95% de confiance peut avoir 70% d'accuracy

Pour les LLMs (Shorinwa et al. 2024)

- La confiance verbalisée ("Je suis certain que...") est peu fiable
- Pas de corrélation claire avec l'accuracy réelle

LLMs : outils, pas oracles


Usages pertinents dans un système adaptatif

- ① **Annotation assistée** (hors ligne)
 - Pré-annotation de corpus pour entraînement
 - Validation humaine nécessaire
- ② **Génération de feedback** (boucle longue)
 - Formulation personnalisée des explications
 - Latence acceptable si pas temps réel
- ③ **Fallback pour cas complexes**
 - Règles simples en première ligne
 - LLM si le cas n'est pas couvert

Usage problématique

Modèle utilisateur direct en temps réel (latence, coût, calibration)

Architecture hybride recommandée



Principe

- Pipeline rapide par défaut (< 100ms)
- LLM en renfort, pas en première ligne
- Découplage inférence temps réel / enrichissement asynchrone

Exemple de recherche : le framework RnB

Problème concret : le *character drift* des LLMs (Shanahan, McDonell et Reynolds 2023)

- Même avec des prompts détaillés, les agents LLM **dérivent comportementalement**
- Absence de contrôlabilité et d'explicabilité

Approche RnB (Sansonnet et Bouchet 2010)

- Couche symbolique **explicite** au-dessus du LLM
- Extraction de schèmes comportementaux depuis **WordNet**
- Traduction des traits **FFM** (Big Five) en opérateurs d'influence
- Garantie de consistance par construction symbolique

Traits personnalité (FFM) → Opérateurs RnB → Influence décisions → LLM génère

Intérêt : Contrôle explicable, latence maîtrisée, LLM = génération, pas décision

→ *Sujet de stage M2 disponible (validation empirique RnB + LLMs modernes)*

Ce qu'on a vu

- ① **Spécificité du texte** : intentionnel mais révélateur (style > contenu)
- ② **Niveaux d'analyse** : lexical → syntaxique → discursif
- ③ **Actes de dialogue** : capturer l'intention, pas juste le contenu
- ④ **Opérationnalisation** : dictionnaires (interprétables) vs ML (performants)
- ⑤ **LLMs** : outils puissants mais pas panacée (calibration, latence, coût)

Trade-off central


Plus un modèle est performant, moins il est interprétable (mais le gap se réduit : Kraus et al. [2024](#))

Tableau récapitulatif

Approche	Interprétabilité	Latence	Quand l'utiliser
Comptage/LIWC	✓✓✓	~ 1ms	Features de base, explicabilité requise
Règles (hedges, questions)	✓✓✓	~ 1ms	Patterns bien définis
ML classique (SVM, RF)	✓✓	~ 10ms	Corpus annoté disponible
Embeddings + MLP	✓	~ 50ms	Besoin de généralisation
LLM (API)	✗	~ 1s	Annotation, génération, cas complexes

PARTIE 2 : APPLICATIONS

Anatomie d'un pipeline



Étape 1 : Prétraitement

Opérations typiques

- Tokenisation (découpage en mots/sous-mots)
- Normalisation (minuscules, accents)
- Gestion de la ponctuation (garder ! et ? pour les émotions)
- Correction orthographique (optionnel, peut perdre de l'info)

Outils Python

- spacy : tokenisation + POS + NER
- nltk : tokenisation + stemming
- Simple : `str.split()` + expressions régulières

Attention : ne pas sur-normaliser

- Les majuscules = emphase → signal
- Les fautes = charge cognitive → signal

Étape 2 : Extraction de features

Features lexicales

```
1 def lexical_features(text, tokens):
2     return {
3         'n_tokens': len(tokens),
4         'n_chars': len(text),
5         'avg_word_len': np.mean([len(t) for t in tokens]),
6         'pct_uppercase': sum(c.isupper() for c in text) / len(text),
7         'n_exclamation': text.count('!'),
8         'n_question': text.count('?'),
9     }
```

Features basées dictionnaire

```
1 UNCERTAINTY_MARKERS = ['peut-etre', 'je pense', 'il me semble',
2     'probablement', 'je crois', 'environ']
3 def uncertainty_score(tokens):
4     text_lower = ' '.join(tokens).lower()
5     return sum(m in text_lower for m in UNCERTAINTY_MARKERS)
```


Étape 2 (suite) : Features discursives

Détection de questions

```
1 def is_question(text):
2     # Règle simple
3     if text.strip().endswith('?'):
4         return True
5     # Mots interrogatifs en debut
6     starters = ['qui', 'que', 'quoi', 'ou', 'quand', 'comment',
7                 'pourquoi', 'est-ce']
8     first_word = text.lower().split()[0] if text.split() else ''
9     return any(first_word.startswith(s) for s in starters)
```

Évolution dans le dialogue

```
1 def dialogue_features(history):
2     n_questions = sum(is_question(turn) for turn in history[-5:])
3     avg_length_trend = ... # Tendance longueur des messages
4     return {'recent_questions': n_questions, ...}
```

Étape 3 : Inférence

Option A : Règles expertes

```
1 def infer_state_rules(features):
2     if features['recent_questions'] >= 3:
3         return {'confusion': 'high'}
4     if features['uncertainty_score'] >= 2:
5         return {'confidence': 'low'}
6     return {'state': 'nominal'}
```

Option B : Modèle ML

```
1 # Pre-entrainement sur corpus avec annotations puis :
2 model = joblib.load('user_state_classifier.pkl')
3 state_proba = model.predict_proba([feature_vector])[0]
```

Option C : Hybride

Règles d'abord → ML si incertain → LLM si vraiment complexe

Étape 4 : Logging des traces

Format xAPI (simplifié)

```
1  {   "actor": {"id": "user_123"},
2      "verb": {"id": "messaging"},
3      "object": {"id": "agent"},
4      "result": {
5          "response": "Je comprends pas trop...",
6          "extensions": {
7              "features": {
8                  "n_tokens": 4,
9                  "uncertainty_score": 1,
10                 "is_question": false
11             },
12             "inferred_state": {
13                 "confusion": 0.7,
14                 "engagement": 0.5
15             }
16         },
17     "timestamp": "2025-12-01T01:23:45Z"
18 }
```

Notebook : pipeline complet sur mini-corpus

→ Voir `ai-adapt-text-demo.ipynb`

Cas 1 : Tuteur intelligent dialogique : AutoTutor (Graesser et al. 2005)

Modélisation utilisateur

- LSA (Latent Semantic Analysis) pour évaluer les réponses
- Détection d'affect via indices textuels + paraverbaux
- Classification des contributions (assertion, question, metacognition)

Adaptation

- Hints progressifs si réponse incomplète
- Reformulation si incompréhension détectée
- Encouragements si frustration détectée

Résultats

~ 0.8σ de gain d'apprentissage (Nye, Graesser et Hu 2014)

Cas 2 : Détection du décrochage : MOOC

Contexte

Forums de discussion dans les cours en ligne

Signaux textuels prédictifs (Chen et al. 2022)

- Déclin de la longueur des posts
- Réduction des marqueurs d'engagement cognitif
- Augmentation des marqueurs de confusion sans résolution
- Pattern temporel : espacement croissant

Adaptation possible

- Alerte aux tuteurs humains
- Message personnalisé de relance
- Suggestion de ressources complémentaires

Cas 3 : Agent conversationnel empathique

Problème

Les chatbots sont perçus comme froids/mécaniques

Approche Empathetic Dialogues (Rashkin et al. 2019)

- Corpus de 25 000 conversations avec émotions explicites
- Modèle entraîné à reconnaître l'émotion ET à générer une réponse appropriée

Composantes de l'adaptation

- 1 Reconnaissance de l'état émotionnel (texte entrant)
- 2 Sélection de stratégie de réponse (réconfort, validation, redirect...)
- 3 Génération adaptée au style de l'utilisateur

Défi

Éviter le "uncanny valley" : trop d'empathie simulée = pire que pas du tout

Points communs des cas d'usage

Dimension	AutoTutor	MOOC dropout	Agent empathique
État modélisé	Connaissance + affect	Engagement	Émotion
Granularité	Tour par tour	Session/semaine	Tour par tour
Boucle	Courte + longue	Longue	Courte
Adaptation	Feedback pédagogique	Intervention	Style de réponse

Constante : le texte seul est souvent insuffisant → multimodalité

Pertinence pour vos projets ?

Questions à se poser

- ① Mon système implique-t-il du **texte utilisateur** ?
 - Chat, formulaires, productions écrites...
- ② Quelle **dimension** veux-je modéliser ?
 - Connaissance, affect, engagement, intention...
- ③ Quelle **boucle** d'adaptation ?
 - Temps réel (feedback) vs différée (scénario)
- ④ Quelles **contraintes** techniques ?
 - Latence, interprétabilité, données disponibles

Biais dans les modèles textuels

Sources de biais

- Corpus d'entraînement non représentatifs
- Biais sociaux encodés dans les embeddings
- Variation de performance selon les groupes démographiques

Exemple concret (Gallegos et al. 2024)

- Détecteurs de "toxicité" → faux positifs sur l'AAVE (African American Vernacular English)
- Sentiment analysis → moins fiable sur textes non-standards

Implications pour l'adaptation

- Un système peut mal modéliser certains utilisateurs
- L'adaptation basée sur un mauvais modèle peut être contre-productive

Vie privée et données textuelles

Le texte est une donnée sensible

- Contenu explicite (opinions, santé, vie privée)
- Style = quasi-identifiant (authorship attribution)
- Historique conversationnel = profil détaillé

Enjeux RGPD

- Consentement éclairé sur l'analyse
- Minimisation des données stockées
- Droit à l'effacement (mais modèle entraîné ?)

Bonnes pratiques

- Extraction de features → suppression du texte brut
- Agrégation / anonymisation
- Transparence sur ce qui est analysé

Subjectivité de l'annotation

Constat empirique (Bobicev et Sokolova 2017)

Accord inter-annotateurs sur les émotions :

- Peur : ~ 68
- Joie : ~ 59
- Colère : ~ 49
- Dégoût : ~ 44
- Moyenne rarement > 75

Implications

- Le "ground truth" est incertain par nature
- Un modèle à 70% d'accuracy peut être au niveau humain
- Métriques de fiabilité (Kappa, Alpha) essentielles

Fragilités des approches textuelles

- Fautes d'orthographe → tokens inconnus
- Registre de langue variable (formel vs argot)
- Multilinguisme / code-switching
- Ironie, sarcasme → inversion du sens
- Très courts messages → peu de signal

Stratégies

- Normalisation robuste (mais pas excessive)
- Modèles tolérants aux erreurs (subword tokenization)
- Incertitude explicite quand signal insuffisant

Points d'attention à garder en tête

① Le texte est riche mais ambigu

- Intentionnel → potentiellement stratégique
- Style révélateur malgré le contrôle conscient

② Les actes de dialogue > le contenu

- Capturer l'intention communicative
- Patterns séquentiels informatifs

③ Plusieurs chemins, aucun parfait

- Dictionnaires : interprétables, limités
- ML : performants, moins explicables
- LLMs : puissants, pas pour le temps réel

④ Le ground truth est incertain


- Humains pas d'accord entre eux
- Calibration des modèles critique

Complémentarités

- Physio : arousal involontaire
- Oculo : attention visuelle
- Haptique : engagement moteur
- **Texte : intention explicite, sémantique**

Le texte comme "ground truth faible" pour les autres modalités ?

L'utilisateur dit "je suis perdu" → valide les signaux physio de stress



Ressources pour aller plus loin

Bibliothèques Python

Outil	Usage principal	Quand l'utiliser
spaCy	Pipeline NLP complet (tokenisation, POS, NER, lemmes)	Standard actuel, production
NLTK	WordNet (synonymes), VADER (sentiment), corpus classiques	Enrichissement lexical, enseignement
Hugging Face	Modèles pré-entraînés (BERT, transformers)	Classification avancée, embeddings

NLTK reste utile pour

- **WordNet** → synonymes, hyperonymes (étendre un dictionnaire : "frustré" → "agacé", "énervé")
- **VADER** → sentiment rule-based calibré réseaux sociaux, interprétable
- **Corpus** → Brown, Reuters, movie_reviews pour expérimenter

Travaux Pratiques

TP : Objectifs et déroulement

Durée totale : ~60 minutes

Phase	Durée	Activité
Exercice 1	20 min	Annotation manuelle de 15 tours
Discussion	5 min	Désaccords et difficultés
Exercice 2	35 min	Implémentation + comparaison

Matériel

- `ai-adapt-text-tp.ipynb` : notebook avec squelette de code
- `corpus_tp_annotation.json` : 15 tours de dialogue à analyser

TP : Consignes Exercice 1

Corpus : 15 tours de dialogue agent conversationnel / utilisateur

Pour chaque tour utilisateur :

Remplir le dictionnaire MES_ANNOTATIONS dans le notebook avec :

① **Acte de dialogue principal**

- Question / Assertion / Request / Confirmation / Expression

② **Niveau d'incertitude perçu (1-5)**

- 1 = très sûr, 5 = très incertain

③ **Affect dominant**

- Positif / Neutre / Négatif / Ambigu

Temps : 15 min individuel, 5 min discussion collective

TP : Consignes Exercice 2

Prérequis : `pip install spacy && python -m spacy download fr_core_news_sm`

Objectif : Découvrir ce que spaCy apporte vs l'approche "à la main" : tokenization, lemmatisation, POS, cas limites (faux positifs, contexte)...

3 fonctions à compléter

- 1 `detect_question_spacy(doc)` — POS tagging pour désambiguïser
- 2 `compute_uncertainty_score(doc)` — score **pondéré** avec lemmes
- 3 `detect_negative_affect(doc)` — gestion des **faux positifs**

Puis :

- Appliquer sur le corpus complet
- Comparer vos annotations manuelles vs spaCy
- Répondre aux 5 questions d'analyse

Bonus : NER et dépendances syntaxiques (si temps restant)

Ce qu'on a vu aujourd'hui

① Le texte : une modalité particulière

- Intentionnel mais révélateur (style > contenu)
- Riche sémantiquement mais ambigu

② Plusieurs niveaux d'analyse

- Lexical → Syntaxique → Discursif (actes de dialogue)
- Les patterns séquentiels sont souvent plus informatifs que les tours isolés

③ Plusieurs approches, chacune avec ses trade-offs

	Règles/Dico	ML classique	LLMs
Interprétabilité	✓✓✓	✓✓	✓
Latence	~1ms	~10ms	~1s
Calibration	Contrôlée	Mesurable	Incertaine

Ce que le TP vous a montré

L'annotation est subjective

- Vous n'êtes pas d'accord entre vous
 - Les "experts" non plus (accord rarement $> 75\%$)
- Le ground truth parfait n'existe pas

De l'artisanal à l'industriel

- Démo : regex, `split()`, dictionnaires → comprendre les principes
- TP : spaCy (POS, lemmes) → voir ce qu'un outil pro apporte
- Lemmatisation : "marchait pas" → détecté !
- POS tagging : "quoi" interrogatif $\neq$ "quoi" relatif

Le bon outil dépend du contexte

- Boucle courte (temps réel) → règles légères
- Cas complexes / annotation → LLM possible
- Production robuste → spaCy + règles métier

Les LLMs sont des outils, pas des oracles.

Pour la modélisation utilisateur en contexte adaptatif :

- Comprendre **ce qu'on mesure** (features interprétables)
- Savoir **quand on se trompe** (incertitude, calibration)
- Adapter **la méthode au besoin** (latence, explicabilité, coût)

Le texte est une fenêtre précieuse sur l'utilisateur,
mais elle reste une fenêtre, pas une porte ouverte sur son esprit.

Si votre système implique du texte utilisateur

- 1 Identifiez les **dimensions** à modéliser (affect, certitude, intention...)
- 2 Choisissez la **granularité** (mot, tour, session)
- 3 Décidez de la **boucle** (courte vs longue)
- 4 Sélectionnez l'**approche** selon vos contraintes

Ressources

- Notebooks de la séance (démonstration + TP)
- Références bibliographiques (slides annexe)
- spaCy, NLTK, Hugging Face pour aller plus loin

Annexe : Références principales I



AUSTIN, John Langshaw (1962). *How to Do Things with Words*. Cambridge, MA : Harvard University Press.



BOBICEV, Victoria et Marina SOKOLOVA (2017). « Inter-Annotator Agreement in Sentiment Analysis : Machine Learning Perspective ». In : *Proceedings of the International Conference on Recent Advances in Natural Language Processing (RANLP)*, p. 97-102.



BOYD, Ryan L. et al. (2022). *The Development and Psychometric Properties of LIWC-22*. Rapp. tech. University of Texas at Austin.



BUNT, Harry et al. (2012). « ISO 24617-2 : A Semantically-Based Standard for Dialogue Annotation ». In : *Proceedings of the 8th International Conference on Language Resources and Evaluation (LREC)*. Istanbul, Turkey, p. 430-437.



CHEN, Jiahao et al. (2022). « Predicting Cognitive Engagement in Online Course Discussion Forums ». In : *Proceedings of the 15th International Conference on Educational Data Mining (EDM)*, p. 239-250.



CORE, Mark G. et James F. ALLEN (1997). « Coding Dialogs with the DAMSL Annotation Scheme ». In : *AAAI Fall Symposium on Communicative Action in Humans and Machines*. Boston, MA.



GALLEGOS, Isabel O. et al. (2024). « Bias and Fairness in Large Language Models : A Survey ». In : *Computational Linguistics*.



GRAESSER, Arthur C. et al. (2005). « AutoTutor : An Intelligent Tutoring System With Mixed-Initiative Dialogue ». In : *IEEE Transactions on Education* 48.4, p. 612-618.



GUO, Chuan et al. (2017). « On Calibration of Modern Neural Networks ». In : *Proceedings of the 34th International Conference on Machine Learning (ICML)*, p. 1321-1330.



HYLAND, Ken (1996). « Writing Without Conviction ? Hedging in Science Research Articles ». In : *Applied Linguistics* 17.4, p. 433-454.

Annexe : Références principales II



HYLAND, Ken (1998). *Hedging in Scientific Research Articles*. T. 54. *Pragmatics & Beyond New Series*. Amsterdam : John Benjamins Publishing Company.



KRAUS, Mathias et al. (2024). « Challenging the Performance-Interpretability Trade-Off : An Evaluation of Interpretable Machine Learning Models ». In : *Business & Information Systems Engineering* 66, p. 373-389.



KUMAR, Harshit et al. (2018). « Dialogue act sequence labeling using hierarchical encoder with CRF ». In : *Proceedings of AAAI*, p. 3440-3447.



LEE, Ji Young et Franck DERNONCOURT (2016). « Sequential short-text classification with recurrent and convolutional neural networks ». In : *Proceedings of NAACL-HLT*, p. 515-520.



NEBEL, Léo et al. (2025). « Towards Automated Characterization of Revision Events in Student Writing ». In : *European Conference on Technology Enhanced Learning*. Springer, p. 397-411.



NYE, Benjamin D., Arthur C. GRAESSER et Xiangen HU (2014). « AutoTutor and Family : A Review of 17 Years of Natural Language Tutoring ». In : *International Journal of Artificial Intelligence in Education* 24.4, p. 427-469.



PENNEBAKER, James W., Martha E. FRANCIS et Roger J. BOOTH (2001). *Linguistic Inquiry and Word Count : LIWC 2001*. Mahwah, NJ : Lawrence Erlbaum Associates.



PENNEBAKER, James W., Matthias R. MEHL et Kate G. NIEDERHOFFER (2003). « Psychological Aspects of Natural Language Use : Our Words, Our Selves ». In : *Annual Review of Psychology* 54, p. 547-577.



RAHEJA, Vipul et Joel TETREAULT (2019). « Dialogue act classification with context-aware self-attention ». In : *Proceedings of NAACL-HLT*, p. 3727-3733.



RASHKIN, Hannah et al. (2019). « Towards Empathetic Open-domain Conversation Models : A New Benchmark and Dataset ». In : *Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics (ACL)*, p. 5370-5381.

Annexe : Références principales III



RAVI, Sujith et Zornitsa KOZAREVA (2018). « Self-governing neural networks for on-device short text classification ». In : *Proceedings of EMNLP*, p. 804-810.



SANSONNET, Jean-Paul et François BOUCHET (2010). « Joint handling of rational and behavioral reactions in assistant conversational agents ». In : *ECAI 2010*.



SEARLE, John Rogers (1969). *Speech Acts : An Essay in the Philosophy of Language*. Cambridge, UK : Cambridge University Press.



SHANAHAN, Murray, Kyle McDONELL et Laria REYNOLDS (2023). « Role play with large language models ». In : *Nature* 623, p. 493-498.



SHORINWA, Oluwatobi et al. (2024). « A Survey on Uncertainty Quantification of Large Language Models : Taxonomy, Open Research Challenges, and Future Directions ». In : *ACM Computing Surveys*.



STOLCKE, Andreas et al. (2000). « Dialogue Act Modeling for Automatic Tagging and Recognition of Conversational Speech ». In : *Computational Linguistics* 26.3, p. 339-373.



TAUSCZIK, Yla R. et James W. PENNEBAKER (2010). « The Psychological Meaning of Words : LIWC and Computerized Text Analysis Methods ». In : *Journal of Language and Social Psychology* 29.1, p. 24-54.



VAN ATTEVELDT, Wouter et al. (2021). « The Validity of Sentiment Analysis : Comparing Manual Annotation, Crowd-Coding, Dictionary Approaches, and Machine Learning Algorithms ». In : *Communication Methods and Measures* 15.2, p. 121-140.