

# Planification et coordination multiagents sous incertitude

Aurélie Beynier

CoCoMa, Master 2 AI2D  
2025-2026

30 octobre 2025

# Organisation

- Aurélie Beynier : aurelie.beynier@lip6.fr
- 4 séances : 30/09, 7/10, 14/10, 14/11
- Planification et coordination multiagents
  - Incertitude, Observabilité, Distribution
  - Planification multiagent sous incertitude
    - Modèles Markoviens mono et multiagents
    - Complexité, algorithmes exacts et approchés
    - Résolution en ligne et apprentissage
  - Optimisation de contraintes distribuée
- 1 mini-projet commun avec la partie 3 de l'UE (N. Maudet)


# Plan

- 1 SMA, planification, incertitude
- 2 Planification mono-agent
  - Décision séquentielle sous incertitude
  - Processus Décisionnels de Markov
  - Processus Décisionnels de Markov Partiellement Observables
- 3 Planification multiagent sous incertitude
  - Problématiques multiagents
  - Notion d'observabilité
  - Exemples de problèmes
  - Exemples Applicatifs
  - Résolution de DEC-POMDPs

# Contexte [Woo02, Wei99]

- Un groupe de  $n$  agents **délibératifs** interagissant dans un même environnement.
- Ces agents doivent anticiper leurs décisions afin de déterminer la suite d'actions la plus favorable permettant d'atteindre leurs buts.
- Nécessité de **planifier** et de **coordonner** les actions des agents

# Contexte



# Pourquoi la coordination ?

## Jennings [Jen96]

La coordination émane des caractéristiques des situations d'interaction :

- Éviter l'anarchie et le chaos
- Augmenter l'efficacité
- Répondre à des contraintes globales
- Distribuer l'information, l'expertise ou les ressources
- Prendre en compte les dépendances entre les actions des agents

# Pourquoi la coordination ?

Coordination basée sur le point de vue d'un agent :

- L'agent décide de ses actions et ses choix affecte ses performances,
- l'ordre dans lequel les activités sont menées affecte les performances,
- l'instant auquel sont exécutées les actions affecte les performances,
- en raison des interactions entre agents, les décisions de chaque agent influence les autres agents.

# Retour sur la planification classique

## Hypothèses

- Observation complète de l'environnement :
  - Champ d'observation ? (portée des capteurs)
  - Observation parfaite ? (bruit des capteurs)
- Communication entre les agents :
  - Communication possible avec tous les agents ?
  - Communication sans bruit ?
  - Communication instantanée et sans bruit ?
- Actions déterministes
  - Modélisation parfaite de l'environnement ?
  - Environnement dynamique ?
  - Comportement parfait des effecteurs ?



# Retour sur la planification classique

## Dans les systèmes réels

- Calcul et exécution décentralisés des plans,
- Les actions ont des durées différentes,
- Le moment où les actions sont exécutées est important,
- Les plans peuvent être affinés par décomposition,
- L'environnement est partiellement observable,
- Le résultat de l'exécution d'une action est incertain.

# Qu'est-ce que l'incertitude ?

- Caractérise le fait qu'un agent ne puisse pas déterminer l'issue d'une action de façon déterministe : l'action ne conduit pas toujours au même résultat
- Concrètement : à partir d'un même état  $s$ , si un agent exécute plusieurs fois une même action  $a$ , il pourra arriver dans différents états  $s'$ .
- Différents types d'incertitude :
  - incertitude sur les issues des actions
  - incertitude sur l'état de l'environnement
  - Incertitude sur les autres agents : états, préférences, actions

# Origine de l'incertitude

## Incertainitude

Observation Partielle + Dynamicit  de l'environnement  $\rightarrow$   
Incertainitude

- Observation partielle de l'environnement et des autres agents :  
port e limit e des capteurs, non-observation des  tats internes  
des autres agents,...



# Origine de l'incertitude - suite

- Observation bruitée
- Modélisation imparfaite ou incorrecte de la dynamique de l'environnement : impossibilité de modéliser tous les événements exogènes, toutes les issues possibles d'une action (toutes les caractéristiques de l'environnement et leur influence sur la dynamique du système,...)
- Effecteurs imparfaits

# Modélisation de l'incertitude

- Probabilités : modèle le plus utilisé pour la décision rationnelle.
  - L'incertitude sur les issues des actions est représentée par des distributions de probabilités.
  - A chaque couple  $(s, a)$  est associé une distribution de probabilités.  $T(s'|s, a)$  correspond à la probabilité de l'issue  $s'$  quand l'action  $a$  est exécutée à partir de  $s$  telle que
$$\sum_{s' \in S} T(s'|s, a) = 1, \forall s \in S, \forall a \in A$$
- Fonctions de croyances de Dempster-Shafer
- Mesures possibilistes
- Fonctions de classement (ranking functions)

Dans ce cours : représentations probabilistes. Plus de détails sur les autres représentations dans [Hal03].

## Gestion de l'incertitude [RN03]

- **Planification sans prise en compte des perceptions** : déterminer un plan qui puisse être exécuté quelles que soient les circonstances et qui ne nécessite donc pas de tenir compte des perceptions
- **Planification conditionnelle** : calculer un plan contingent ayant différentes branches correspondant aux différentes séquences d'exécution possibles. Les perceptions permettent, à l'exécution, de savoir dans quelle branche on se situe.
- **Replanification à l'exécution** : calculer un plan en utilisant des techniques classiques et détecter à l'exécution si on a dévié de la situation prévue. Si c'est le cas, on replanifie en tenant compte de la situation effective.
- **Planification continue** : l'agent planifie continuellement au cours de l'exécution en fonction des avancées et des résultats de ses actions.

# Cadre de la décision séquentielle sous incertitude

- Hypothèse : on dispose d'une représentation probabiliste des issues des actions (ou on peut en apprendre une) → fonction de transition entre les états connue
- Objectifs : décider quelle est la meilleure action à faire à chaque pas de temps étant données les évolutions futures possibles → **Décision séquentielle**
- Idée : trouver un plan qui permet de maximiser les performances de l'agent (ou des agents) étant données les informations dont il dispose sur l'environnement → **Décision rationnelle**

# Décision séquentielle sous incertitude : cas mono-agent


- Commençons par considérer le cas (plus simple) d'**un seul agent**
- On considère des problèmes de **décision séquentielle** : à chaque pas de temps l'agent doit décider comment agir
- **Sous incertitude** : le résultat de l'action est incertain
- Différents niveaux d'observabilité sont envisageables :
  - Observabilité complète : l'agent connaît, à chaque pas de temps, l'état du système
  - Observabilité partielle : l'agent n'observe, à chaque pas de temps, qu'une partie de l'état du système. Il doit donc faire des hypothèses sur l'état sous-jacent à partir de ses observations



# Décision séquentielle sous incertitude : cas mono-agent

Un exemple : Robot se déplaçant dans un couloir

- Distance parcourue par le robot incertaine : *lorsqu'il entreprend un déplacement long : la probabilité qu'il avance de 3 mètres est de 20%, la probabilité qu'il avance de 4 mètres est de 60%, la probabilité qu'il avance de 5 mètres est de 20%.*
- Le robot doit s'arrêter devant la troisième porte → objectif, récompense attribuée lorsque le robot atteint un tel état



*extrait de Amato et al.*

# Rationalité et théorie de l'utilité

- Un agent possède des préférences sur les différentes issues des plans.
- Dans la théorie de l'utilité, les préférences sont représentées par un degré d'utilité.
- L'incertitude est représentée par des distributions de probabilités
- L'utilité espérée d'une action représente la moyenne pondérée des utilités sur les différentes issues de l'action :

$$UE(a|s) = \sum_{s'} P(s'|a, s) U(s') \quad (1)$$

# Rationalité et théorie de l'utilité

## Principe de maximisation de l'utilité espérée

En théorie de la décision, un agent est rationnel, si et seulement si, il choisit à chaque instant l'action qui maximise son utilité espérée. [Ber54, NM53].

Soit  $\pi^*$  la politique (stratégie optimale) à partir de  $s$ , on a :

$$\pi^*(s) = \arg\_max_a EU(a|s)$$

# Décision séquentielle

- L'équation 1 suppose que l'agent ne prend qu'une seule décision (on considère l'utilité de l'état suivant).
- La décision séquentielle suppose que l'agent va devoir prendre une série de décisions.
- L'utilité espérée est définie sur la séquence des états qui vont suivre. Cette séquence dépend des actions qui vont être exécutées par l'agent donc de la politique  $\pi$  suivie par l'agent :

$$U^\pi(s) = E \left[ \sum_{t=0}^{\infty} \gamma^t R(s_t) | \pi, s_0 = s \right] \quad (2)$$

# Décision séquentielle

En utilisant le principe de maximisation de l'utilité espérée, Bellman [Bel03] a montré que l'utilité d'un état  $s$  est définie par la somme entre le gain immédiat pour être en  $s$  et l'utilité espérée pondérée des états suivants en supposant que l'agent suit une politique optimale à partir de ces états :

$$U(s) = R(s) + \gamma \max_a \sum_{s'} P(s'|s, a) U(s') \quad (3)$$

La politique optimale  $\pi^*$  à partir de  $s$  est alors donnée par :

$$\pi^*(s) = \arg\_max_a \sum_{s'} P(s'|s, a) U(s') \quad (4)$$

# Processus Décisionnels Markoviens

- Les Processus Décisionnels de Markov (MDPs) et les Processus Décisionnels de Markov Partiellement Observables (POMDPs) [Put05] permettent de formaliser des problèmes de décision séquentielle mono-agent sous incertitude.
- MDP pour le cas totalement observable
- POMDP pour le cas partiellement observable

# Processus Décisionnels Markoviens

- Un MDP est défini par un tuple  $\langle S, A, T, R \rangle$ 
  - $S$  : l'ensemble des états  $s$  du système
  - $A$  : l'ensemble des actions  $a$  de l'agent
  - $T$  : la fonction de transition modélisant l'incertitude,  
 $T(s'|s, a)$  est la probabilité de passer d'un état  $s$  à un état  $s'$  en effectuant l'action  $a$
  - $R$  : la fonction de récompense modélisant les objectifs de l'agent,  $R(s, a)$  est la récompense obtenue par l'agent lorsque l'action  $a$  est exécutée partir de l'état  $s$ .

# Processus Décisionnels Markoviens

**Formalisons le problème de décision du robot dans le corridor sous forme d'un MDP**

- Un MDP est défini par un tuple  $\langle S, A, T, R \rangle$ 
  - $S : ?$
  - $A : ?$
  - $T : ?$
  - $R : ?$



# Processus Décisionnels Markoviens

## Formalisons le problème de décision du robot dans le corridor sous forme d'un MDP

- Un MDP est défini par un tuple  $\langle S, A, T, R \rangle$ 
  - $S$  : position du robot dans un espace à une dimension
  - $A$  : longMove ou shortMove ou stop
  - $T$  :  $T(s, stop, s) = 1$ ,  $T(1, longmove, 4) = 0.2$ ,  
 $T(1, longmove, 5) = 0.6$ ,  $T(1, longmove, 6) = 0.2$ ,  
 $T(1, shortmove, 1) = 0.2$ ,  $T(1, shortmove, 2) = 0.6$ ,  
 $T(1, shortmove, 3) = 0.2, \dots$
  - $R$  : récompense positive si on est devant la porte, sinon récompense nulle

# Processus Décisionnels Markoviens

- Une solution à un problème formalisé sous forme de MDP est une politique :

$$\pi : S \rightarrow A$$

- Par exemple :  $1 \rightarrow longMove$ ,  $2 \rightarrow longMove$ ,  $\dots$ ,  
 $19 \rightarrow shortMove$ ,  $20 \rightarrow stop$
- La politique optimale est telle que :

$$\pi^*(s) = \underset{a}{argmax} \left\{ R(s, a) + \gamma \sum_{s' \in S} T(s, a, s') \times V^{\pi^*}(s') \right\} \quad (5)$$

- Des algorithmes efficaces de résolution existent pour calculer la politique optimale (itération de la valeur, itération des politiques, ...)

# Processus Décisionnels Markoviens Partiellement Observables

- Un POMDP est défini par un tuple  $\langle S, A, T, O, \Omega, R \rangle$ 
  - $S, A, T, R$  identiques à un MDP
  - $O$  : l'ensemble des observations  $o$  de l'agent
  - $\Omega$  : la fonction d'observation,  $\Omega(O|s', a)$  est la probabilité d'obtenir l'observation  $o$  lorsque l'agent exécute l'action  $a$  et arrive dans l'état  $s'$

# Processus Décisionnels Markoviens Partiellement Observables

## Formalisons le problème de décision du robot dans le corridor sous forme d'un POMDP

Le robot ne perçoit que la présence d'une porte ou d'un mur du corridor, pas sa position.

- $S : ?$
- $A : ?$
- $T : ?$
- $R : ?$
- $O : ?$
- $\Omega : ?$

# Processus Décisionnels Markoviens Partiellement Observables

## Formalisons le problème de décision du robot dans le corridor sous forme d'un POMDP

- $S$  : position du robot dans un espace à une dimension
- $A$  : move ou stop
- $T$  :  $T(s, stop, s) = 1$ ,  $T(1, longmove, 4) = 0.2$ ,  
 $T(1, longmove, 5) = 0.6$ ,  $T(1, longmove, 6) = 0.2$ ,  
 $T(1, shortmove, 1) = 0.2$ ,  $T(1, shortmove, 2) = 0.6$ ,  
 $T(1, shortmove, 3) = 0.2, \dots$
- $R$  : récompense positive si on est devant la porte, sinon récompense nulle
- $O$  : door ou corridor
- $\Omega$  : par exemple 10% de bruit sur les observations  
 $P(door, 2, stop) = 0.1$ ,  $P(corridor, 2, stop) = 0.9$ , ...

# Processus Décisionnels Markoviens Partiellement Observables

- A partir de ses observations, l'agent essaye de déterminer dans quel état il se trouve : pour cela il maintient des *beliefs* sur son état :  $b(s)$  est la probabilité que l'agent soit dans l'état  $s$
- Les probabilités sur les *beliefs* sont mises à jour en appliquant la règle de Bayes :

$$b'(s') \propto p(o|s') \sum_s p(s'|s, a) b(s)$$


- Complexité algorithmique plus importante : on préfère les méthodes approchées (algo le plus efficace actuellement POMCP)

# Processus Décisionnels Markoviens Partiellement Observables

True situation:




Robot's belief:




- ▶ Observations: *door* or *corridor*, 10% noise.
- ▶ Action: moves 3 (20%), 4 (60%), or 5 (20%) states.

# Processus Décisionnels Markoviens Partiellement Observables

True situation:



Robot's belief:



- ▶ Observations: **door** or *corridor*, 10% noise.
- ▶ Action: moves 3 (20%), 4 (60%), or 5 (20%) states.




# Processus Décisionnels Markoviens Partiellement Observables

True situation:



Robot's belief:



- ▶ Observations: **door** or *corridor*, 10% noise.
- ▶ Action: moves 3 (20%), 4 (60%), or 5 (20%) states.


*extrait de Amato et al.*

# Processus Décisionnels Markoviens Partiellement Observables

True situation:




Robot's belief:



- Observations: **door** or *corridor*, 10% noise.
- Action: moves 3 (20%), 4 (60%), or 5 (20%) states.

# Processus Décisionnels Markoviens Partiellement Observables

True situation:




Robot's belief:




- Observations: *door* or **corridor**, 10% noise.
- Action: moves 3 (20%), 4 (60%), or 5 (20%) states.

# Processus Décisionnels Markoviens Partiellement Observables

True situation:



Robot's belief:



- Observations: *door* or **corridor**, 10% noise.
- Action: moves 3 (20%), 4 (60%), or 5 (20%) states.

# Processus Décisionnels Markoviens

- Les MDPs et POMDPs ont été utilisés avec succès dans de nombreux domaines : routage dans les réseaux, étude de phénomènes biologiques et écologiques, gestion de dialogue, robotique exploratoire, problème de navigation,...
- Les MDPs et POMDPs sont mal adaptés à la formalisation de problèmes de décision multiagent :
  - 1 action par agent
  - 1 état pour chaque agent
  - les agents ont une observabilité partielle de l'état du système
  - le contrôle est décentralisé

# Planification multiagent sous incertitude

- Revenons au cas multiagent
- **Plusieurs agents délibératifs** évoluant dans **un même environnement**
- Chaque agent est **autonome** et décide de ses actions : prise de décision distribuée (pas de décideur central, pas de communication ou bien restreinte)
- Décision séquentielle
- Incertitude
- Observabilité partielle

# Planification multiagent sous incertitude

Dans les systèmes multiagents :

- l'issue d'une action d'un agent dépend le plus souvent des actions des autres agents
- l'utilité d'un agent dépend le plus souvent des états des autres agents
- nécessité de tenir compte des interactions entre agents et de coordonner les plans des agents
- les agents peuvent rarement se limiter à maximiser indépendamment leurs utilités individuelles

De plus :

- les agents ont le plus souvent une observabilité partielle du système (environnement et autres agents)
- les agents ne connaissent donc pas les plans des autres agents
- les communications entre agents sont le plus souvent limitées (bande passante limitée, coût en temps de communication, impossibilité physique de communiquer,...)

# Problématique

## Problématique

On souhaite former un groupe d'agents qui agit de manière rationnelle et coordonnée dans un environnement incertain et dynamique.

On s'intéressera ici aux agents coopératifs, c'est-à-dire ayant une fonction d'utilité commune qu'ils cherchent à maximiser.



# Problématique

## Exemples d'applications

- Routage dans les réseaux
- Constellations de satellites
- Colonies de robots : navigation, exploration, missions de secours
- Gestion d'accès multiples (à un canal de communication par exemple)
- Réseaux de capteurs

# Processus Décisionnels Markoviens Multiagent

Différents modèles proposés selon :

- le degré d'observabilité de l'état du système et des états des agents
- les indépendances entre les agents (transitions, observations, récompenses)
- la présence ou non de communication entre les agents

Différentes approches de résolution :

- Optimale ou approchée
- Centralisée ou décentralisée
- Exploitant ou non la structure du problème (contraintes de ressources, temporelles, structure des interactions)

# Différents types d'observabilité

## État du système

États des agents + état de l'environnement

## Observabilité de l'état du système

- Individuellement Observable : chaque agent observe l'état du système
- Collectivement Totalement Observable : l'union des observations des agents permet de déduire l'état du système
- Collectivement Partiellement Observable : l'union des observations des agents permet de déduire une partie de l'état du système
- Non Observable : aucune observation de l'état du système

# Différents types d'observabilité

## État d'un agent

Défini selon le degré de délibération de l'agent.

Perceptions courantes de l'agent ou représentation interne de ses connaissances.

## Observabilité de l'état d'un agent

- Totalement Observable
- Partiellement Observable
- Non Observable

# Observabilité et Incertitude dans les SMA

En plus de l'incertitude sur les issues des actions et l'état de l'environnement, on doit faire face à :

- l'incertitude sur les états / croyances des autres agents : les autres agents peuvent obtenir des observations différentes.
- l'incertitude sur les préférences des autres agents (cadre non coopératif) : les fonctions de récompenses et les objectifs des autres agents ne sont pas forcément connus des autres agents
- l'incertitude sur les actions des autres agents : si les états et/ou les préférences des autres agents sont incertains, un agent ne peut pas prédire avec certitude les actions exécutées par les autres agents.

## Exemple de problème (1)

“Multiagent Tiger Domain” [NTY<sup>+</sup>03]



## Exemple de problème (1)

### “Multiagent Tiger Domain”


- Derrière l'une des portes un tigre, derrière l'autre un trésor
- 2 agents pouvant ouvrir individuellement ou conjointement une des portes
- Les agents peuvent indépendamment écouter s'ils entendent le tigre derrière l'une des portes. Les perceptions sont bruitées.
- S'ils ouvrent conjointement la porte derrière laquelle est le tigre, ils sont moins blessés que s'ils l'ouvrent individuellement (pénalité).
- Les agents reçoivent la récompense maximum lorsqu'ils ouvrent conjointement la porte du trésor

⇒ Les agents doivent se coordonner

## Exemple de problème (2)

“Rencontre sur une grille” [BHZ05]

- Grille 2x2 et 2 robots
- Les robots ne perçoivent que les murs (contours de l'environnement)
- Pas de perception de la position de l'autre robot
- Les déplacements des robots sont incertains
- Objectif : les robots doivent rester le plus longtemps possible sur la même case





## Exemple de problème (3)

### “Multi-access broadcast channel” [BHZ05]

- Des nœuds émettent des messages en “broadcast” sur un canal commun.
- Les nœuds du canal ne peuvent pas émettre en même temps (collision).
- L’envoi d’un message sans collision rapporte une récompense.
- Le buffer d’envoi de chaque nœud a une capacité de 1 message. Lorsqu’un message est envoyé, l’ajout d’un nouveau message dans le buffer d’envoi est non-déterministe.
- Objectif : les nœuds cherchent à maximiser l’utilisation du canal.

## Exemple de problème (4)

### Exploration multi-robot [BM06, EMGST04]

- Un ensemble de  $m$  sites à explorer par un ensemble de  $n$  robots mobiles  $n < m$
- Les robots ont des actions à réaliser sur chaque site. Il existe des dépendances entre les actions réalisées par des robots différents (contraintes de précédence, de simultanéité,...)
- Les robots ont des ressources limitées
- Chaque action peut échouer. L'exécution réussie d'une action (action menée à son terme sans erreur et en respectant les contraintes) rapporte une récompense.
- Objectif : maximiser les récompenses obtenues par le système

# MMDP (Multiagent Markov Decision Processes)

## Définition

Un MMDP [Bou96] est défini par un tuple  $\langle \alpha, \mathcal{S}, \mathcal{A}, \mathcal{T}, \mathcal{R} \rangle$  tel que :

- $\alpha$  est le nombre d'agents du système.
- $\mathcal{S}$  correspond à l'ensemble des états  $s$  du système.
- $A = A_1 \times \dots \times A_n$  définit l'ensemble des actions jointes  $a$  des agents,  $A_i$  est l'ensemble des actions locales de l'agent  $i$ .
- $\mathcal{T}$  est une fonction de transition, elle donne la probabilité  $\mathcal{T}(s, a, s')$  que le système passe dans un état  $s'$  quand les agents exécutent l'action jointe  $a$  à partir de l'état  $s$ .
- $\mathcal{R}$  définit la fonction de récompense.  $\mathcal{R}(s, a, s')$  est la récompense obtenue par le système lorsqu'il passe d'un état  $s$  à un état  $s'$  en exécutant l'action  $a$ .

# Processus Décisionnels de Markov Multi-agents

## Résolution

- Un MMDP peut être vu comme un MDP ayant un grand espace d'états et d'actions.
- Résoudre un MMDP consiste à calculer une politique jointe  $\pi = \langle \pi_1, \dots, \pi_n \rangle$  où  $\pi_i$  correspond à la politique locale de l'agent  $i$ . Elle définit une fonction  $\pi_i : S \rightarrow A_i$ .
- Résolution à l'aide d'algorithmes classiques comme l'itération de la valeur.

## Discussion

Les MMDP supposent que l'état du système soit individuellement observable ou bien que la communication soit gratuite  $\Rightarrow$  peu réaliste dans les SMA.

# Processus Décisionnels de Markov Partiellement Observables Décentralisés [Oli12]

## Définition

Un DEC-POMDP est défini par un tuple  $\langle \mathcal{S}, \mathcal{A}, \mathcal{T}, \Omega, \mathcal{O}, \mathcal{R} \rangle$  tel que :

- $\mathcal{S}$  définit l'état global du système.
- $\mathcal{A} = A_1 \times \dots \times A_n$  est l'ensemble des actions jointes et  $A_i$  définit l'ensemble des actions  $a_i$  de l'agent  $i$ .
- $\mathcal{T} = \mathcal{S} \times \mathcal{A} \times \mathcal{S} \rightarrow [0, 1]$  définit la fonction de transition.  $\mathcal{T}(s, a, s')$  correspond à la probabilité que le système passe d'un état  $s$  à un état  $s'$  lorsque l'action jointe  $a$  est exécutée.
- $\Omega = \Omega_1 \times \Omega_2 \times \dots \times \Omega_n$  est l'ensemble des observations des agents et  $\Omega_i$  est l'ensemble des observations de l'agent  $i$ .
- $\mathcal{O} = \mathcal{S} \times \mathcal{A} \times \mathcal{S} \times \Omega \rightarrow [0, 1]$  définit la fonction d'observation.  $\mathcal{O}(s, a, s', o = \langle o_1, \dots, o_n \rangle)$  correspond à la probabilité que chaque agent  $i$  observe  $o_i$  lorsque les agents exécutent l'action jointe  $a$  à partir de l'état  $s$  et que le système arrive dans l'état  $s'$ .
- $\mathcal{R}$  définit la fonction de récompense.  $\mathcal{R}(s, a, s')$  est la récompense obtenue par le système lorsque les agents exécutent l'action  $a$  à partir de l'état  $s$  et arrivent dans l'état  $s'$ .

# Processus Décisionnels de Markov Décentralisés


## Définition

Un DEC-MDP est un DEC-POMDP où l'état du système est collectivement totalement observable :

$$\mathcal{O}(s, a, s', o = \langle o_1, \dots, o_n \rangle) > 0 \text{ alors } P(s' | \langle o_1, \dots, o_n \rangle) = 1$$

**Attention :** cela ne signifie pas que chaque agent observe totalement son état local. De plus, l'état global du système n'est pas pour autant individuellement observable.

# Processus Décisionnels de Markov Décentralisés



**Figure:** Relations entre les différents types de Processus Décisionnels de Markov

# Multiagent Tiger Domain

- États :  $S = \{SL, SR\}$  indique derrière quelle porte est le tigre
- Actions :  $A_1 = A_2 = \{\text{OpenLeft}, \text{OpenRight}, \text{Listen}\}$
- Observations :  $\Omega_1 = \Omega_2 = \{HL, HR\}$ , indépendantes et bruitées
- La fonction de transition  $\mathcal{T}$  spécifie, chaque fois qu'une porte est ouverte, où sont replacés le tigre et le trésor
- La fonction d'observation retourne soit  $HL$  soit  $HR$  avec différentes probabilités suivant l'action jointe et l'état du monde
- La fonction de récompense traduit les pénalités et les récompenses obtenues pour ouvrir individuellement ou conjointement une des portes. Par exemple : Si l'état est  $SL$  et l'action réalisée est  $\langle \text{OpenRight}, \text{OpenRight} \rangle$  alors les agents obtiennent la récompense 20. Si l'état est  $SR$ , ils obtiennent la récompense -50.



# Rencontre sur une grille

- États : positions des 2 robots (4 positions possibles pour chaque robot  $\rightarrow$  16 états)
- Actions :  $A_1 = A_2 = \{\text{up, down, right, left, stop}\}$ . Un déplacement vers un mur conduit à rester sur place.
- Observations :  $\Omega_1 = \Omega_2 = \{WL, WR, WL\&WR, \emptyset\}$
- La fonction de transition  $\mathcal{T}$  détermine si le robot se déplace dans la direction souhaitée ou non.
- La fonction d'observation retourne une des observations avec différentes probabilités suivant l'action jointe et l'état du monde.
- Fonction de récompense : les robots reçoivent une récompense de 1 quand ils sont sur la même case, 0 sinon.

# Multi-Access Broadcast Channel

- États : 4 états possibles suivant que le buffer de chaque agent est vide ou non
- Actions :  $A_1 = A_2 = \{\text{Send, Nothing}\}$
- Observations : chaque nœud observe si son buffer est vide ou non et si l'étape précédente a conduit à une collision, un envoi réussit ou rien  $\rightarrow$  5 observations.
- La fonction de transition  $\mathcal{T}$  spécifie, comment est re-rempli un buffer quand il est vide (probabilité qu'un message apparaisse).
- Fonction d'observation déterministe
- Fonction de récompense : récompense de 1 quand un message est envoyé avec succès, 0 sinon

# Politique distribuée


## Résolution

- Résoudre un DEC-POMDP consiste à calculer une politique jointe  $\pi = \langle \pi_1, \dots, \pi_n \rangle$  où  $\pi_i$  correspond à la politique locale de l'agent  $i$ .
- Cette politique peut être calculée *off-line* de manière centralisée.
- La politique est toujours exécutée de manière distribuée : chaque agent doit donc être en mesure de déterminer quelle action exécuter à partir de ses observations.

# Politique distribuée

Off-line

On-line



# Politique distribuée

## Historique observations-actions

Un historique d'observations-actions pour un agent correspond à la séquence d'actions et d'observations réalisées par l'agent :

$$\bar{\theta}_i^t = (o_i^1, a_i^1, o_i^2, a_i^2, \dots, o_i^t, a_i^t)$$

## Historique observations

Un historique d'observations pour un agent correspond à la séquence d'observations réalisées par l'agent :

$$\bar{\theta}_i^t = (o_i^1, o_i^2, \dots, o_i^t)$$

# Politique distribuée

## Politique : cas général

Dans le cas général, une politique fait correspondre une action à chaque historique observations-actions.

## Politique déterministe

Une politique déterministe fait correspondre une action à chaque historique d'observations.

## Politique optimale d'un DEC-POMDP


Il existe une politique optimale déterministe pour tout DEC-POMDP.

La politique optimale d'un DEC-POMDP à  $n$  agents est de la forme  $\pi = \langle \pi_1, \dots, \pi_n \rangle$  où :

$$\pi_i = \bar{O}_i \rightarrow A_i$$


# Politique distribuée

Exemple de politique individuelle pour DEC-Tiger (politique de 1 agent) avec horizon 3 :



# Politique distribuée

Exemple de politique individuelle pour DEC-Tiger (politique de 1 agent) avec horizon 4 :





# Calcul de politiques optimales

- A l'étape de décision  $t$ , il existe pour l'agent  $i$  :  $(|A_i| \cdot |\Omega_i|)^t$  historiques observations-actions possibles. Une politique  $\pi_i$  assigne une action à chacun de ces historiques (taille de la politique à l'étape  $t$  pour un agent  $i$ ).
- Donc calculer une politique optimale pour un DEC-POMDP n'est pas simple !
- Algorithme naïf :
  - Pour chaque politique jointe  $\pi$ , calculer  $V(\pi)$
  - Sélectionner le max de  $V(\pi)$

# Calcul de politiques optimales

- Le nombre de politiques jointes est doublement exponentiel !
- Plus précisément, pour un horizon  $h$ , le nombre de politiques jointes est :

$$O(|A_{\dagger}|^{\frac{n(|\Omega_{\dagger}|^h - 1)}{|\Omega_{\dagger}| - 1}})$$

où  $\dagger$  désigne les ensembles d'actions et d'observations individuels de taille maximale.

- L'évaluation du politique jointe a un coût en :



$$O(|S| \cdot |\Omega_{\dagger}|^{nh})$$

- Résoudre de manière optimale un DEC-POMDP est NEXP-complet [BZI02]



# Calcul de politiques optimales

 $a_1$  $a_2$  $a_1$  $a_2$

# Calcul de politiques optimales



# Calcul de politiques optimales



# Classes de complexité

Cas particuliers :

- État du système individuellement totalement observable : le problème peut se réduire à un MDP dont la résolution est P-Complète.
- État global du système n'est pas observable : le problème se réduit à un MDP non observable (NOMDP) connu pour être NP-complet.

| Observabilité de l'état du système | Individuellement Observable | Collectivement Observable | Collectivement Partiellement Observable | Non Observable |
|------------------------------------|-----------------------------|---------------------------|-----------------------------------------|----------------|
| Complexité                         | P-complet                   | NEXP-Complet              | NEXP-Complet                            | NP-Complet     |

**Table:** Observabilité et Complexité en temps

# Résolution des DEC-POMDPs

- Approches optimales pour la résolution de DEC-POMDPs :
  - Élimination itérative de stratégies dominées
  - Heuristiques guidant la résolution (type A\*)
  - Identifier des propriétés des problèmes pouvant être exploitées afin de diminuer la complexité de résolution : indépendances des observations, des transitions, existence d'états buts, localité des interactions,...
  - Ramener le problème à un MDP déterministe et à états continus
- Approches alternatives :
  - Chercher une solution approchée de la solution optimale.

# Références I



Richard Ernest Bellman, *Dynamic programming*, Dover Publications, Incorporated, 2003.



D. Bernoulli, *Exposition of a new theory on the measurement of risk*, University of Chicago Press, 1954.



D. Bernstein, E.A Hansen, and S. Zilberstein, *Bounded policy iteration for decentralized pomdps*, Proceedings of the Nineteenth International Joint Conference on Artificial Intelligence (Edinburgh, Scotland), 2005.



A. Beynier and A.I Mouaddib, *An iterative algorithm for solving constrained decentralized markov decision processes*, The Twenty-First National Conference on Artificial Intelligence (AAAI-06), 2006.



C. Boutilier, *Planning, learning and coordination in multiagent decision processes*, Proceedings of the 6th Conference on Theoretical Aspects of Rationality and Knowledge (TARK'96), 1996, pp. 195–201.



## Références II



D. Bernstein, S. Zilberstein, and N. Immerman, *The complexity of decentralized control of mdps*, Mathematics of Operations Research, 2002, pp. 27(4):819–840.



R. Emery-Montemerlo, G. Gordon, J. Schneider, and S. Thrun, *Approximate solutions for partially observable stochastic games with common payoffs*, Proceedings of the Third Joint Conference on Autonomous Agents and Multi Agent Systems, 2004.



Joseph Y. Halpern, *Reasoning about uncertainty*, MIT Press, Cambridge, MA, USA, 2003.



N. R. Jennings, *Coordination techniques for distributed artificial intelligence*, 1996.



John Neumann and Oskar Morgenstern, *Theory of games and economic behavior*, 3. ed. ed., Princeton Univ. Press, 1953.

## Références III



R. Nair, M. Tambe, M. Yokoo, S. Marsella, and D.V Pynadath, *Taming decentralized pomdps: Towards efficient policy computation for multiagent settings*, Proceedings of the International Joint Conference on Artificial Intelligence, 2003, pp. 705–711.



Frans A. Oliehoek, *Decentralized POMDPs*, Adaptation, Learning, and Optimization, vol. 12, pp. 471–503, Springer Berlin Heidelberg, Berlin, Germany, 2012.



M. L Puterman, *Markov decision processes : discrete stochastic dynamic programming*, Wiley-Interscience, New York, 2005.



S. Russell and P. Norvig, *Artificial intelligence : A modern approach*, Prentice Hall Series, 2003.



G Weiss, *Multiagent systems a modern approach to distributed artificial intelligence*, MIT Press, 1999.

# Références IV



M. Wooldridge, *An introduction to multiagent systems*, John Wiley and Sons, 2002.