

Confiance humaine en l'IA

définition, mesures, facteurs

Human-AI Interaction - S3 | Master AI2D

Objectifs d'apprentissage

- Savoir définir la confiance et savoir quand il est pertinent d'en parler
- Savoir comment la mesurer
- Savoir quels facteurs peuvent l'influencer

La confiance humain-IA : pourquoi est-ce important ?

C'est ainsi que les décideurs politiques l'interprètent - pas pertinent pour nous:

- un moyen de mettre **en place** les **principes éthiques** liés à une IA *digne de confiance* (trustworthy AI) = mesure/indicateur

C'est ainsi que les gouvernements et les entreprises l'interprètent - pas pertinent pour nous et pas nécessairement vrai:


- un moyen de favoriser l'**adoption de l'IA** (↑ innovation; ↑ ventes)



Interprétation centrée sur l'humain:

- un moyen d'**améliorer la performance** de l'équipe humaine-IA

(lorsque $p(H) \neq p(IA)$)



! l'objectif $\neq$ niveau de confiance élevé
= confiance correctement calibrée

Pour calibrer la confiance, il faut comprendre

- quels sont les **facteurs** qui impactent les niveaux de confiance dans l'IA
- comment **mesurer** la confiance



Ok, c'est bon, allons-y ?

Pas si vite !

Tout d'abord, il faut bien **définir** la notion de confiance.

Définition de « confiance »

Temps très limité



La personne n'est pas l'expert

Q: Cette personne fait-elle confiance à ce système basé sur l'IA ?

Oui

Non

Cela dépend

Définition de « confiance »

- ce n'est pas un comportement (externe), c'est une **attitude** (interne).

S	
A	
B	
C	
D	
F	
Difficile à répondre	

Q: Dans quelle mesure faites-vous confiance en l'IA ?

S	
A	
B	
C	
D	
F	
Difficile à répondre	

Q: Dans quelle mesure faites-vous confiance en l'IA ?



la question n'est pas assez pertinente: le contexte manque

Définition de « confiance »

- ce n'est pas un comportement (externe), c'est une **attitude** (interne);
- la confiance n'est pas toujours « activée », nous avons besoin d'un contexte spécifique pour qu'elle « s'enclenche » :
 - un **objectif** spécifique

S	
A	
B	I A
C	I A
D	I A
F	
Difficile à répondre	I A

Q: Dans quelle mesure faites-vous confiance à l'IA pour vous donner les meilleures recommandations pour vos décisions ?



S	
A	
B	
C	
D	
F	
Difficile à répondre	

Q: Dans quelle mesure faites-vous confiance à l'IA pour vous donner les meilleures recommandations pour vos décisions ?

IA

Définition de « confiance »

- ce n'est pas un comportement (externe), c'est une **attitude** (interne);
- la confiance n'est pas toujours « activée », nous avons besoin d'un contexte spécifique pour qu'elle « s'enclenche » :
 - un **objectif** spécifique
 - un élément de **vulnérabilité** (conséquences)
 - un élément d'**incertitude** (dépendance)

Définition de « confiance »

- ce n'est pas un comportement (externe), c'est une **attitude** (interne);
- la confiance n'est pas toujours « activée », nous avons besoin d'un contexte spécifique pour qu'elle « s'enclenche » :
 - un **objectif** spécifique
 - un élément de **vulnérabilité** (conséquences)
 - un élément d'**incertitude** (dépendance)



Confiance = l'**attitude** qui consiste à croire qu'un agent aidera un individu à **atteindre ses objectifs** dans une situation caractérisée par l'**incertitude et la vulnérabilité** (Lee and See, 2004)

Définition de « confiance »



Définition de « confiance » en l'IA

confiance en l'IA = en tant que classe de systèmes

confiance en l'IA = entreprise qui développe l'outil d'IA

confiance en l'IA = ce système spécifique intégrant l'IA

confiance en l'IA = pas un système en soi, mais le modèle d'IA lui-même

confiance en l'IA = une explication de l'IA

Comment mesurer la confiance Humain-AI ?

! Nous ne pouvons pas nous fier
uniquement aux *observations* et aux
logs comportementaux (idéalement)

= reliance, taux d'accord

Confiance = l'**attitude** qui consiste à croire
qu'un agent aidera un individu à atteindre
ses objectifs dans une situation
caractérisée par l'incertitude et la
vulnérabilité (Lee and See, 2004)

Comment mesurer la confiance Humain-AI ?

! Nous ne pouvons pas nous fier uniquement aux *observations* et aux *logs comportementaux* (idéalement)

= reliance, taux d'accord

Il faut poser des questions :

Entretiens (informatif, pas toujours pratique/possible)

Questionnaires (moins informatif, plus pratique)

Think aloud (informatif, pas toujours pratique/possible)

Confiance = l'**attitude** qui consiste à croire qu'un agent aidera un individu à atteindre ses objectifs dans une situation caractérisée par l'incertitude et la vulnérabilité (Lee and See, 2004)

Comment mesurer la confiance Humain-AI ?

! Nous ne pouvons pas nous fier uniquement aux *observations* et aux *logs comportementaux* (idéalement)


= reliance, taux d'accord

Il faut poser des questions :

Entretiens (informatif, pas toujours pratique/possible)

Questionnaires (moins informatif, plus pratique)

Think aloud (informatif, pas toujours pratique/possible)



Confiance = l'**attitude** qui consiste à croire qu'un agent aidera un individu à atteindre ses objectifs dans une situation caractérisée par l'incertitude et la vulnérabilité (Lee and See, 2004)

<https://tinyurl.com/5duzwd7p>

#2.10, #2.11, #3.2

#2.1

Une petite remarque concernant les logs comportementaux

Il est toujours intéressant à consulter, mais ne déclarez pas que vous avez mesuré la confiance !

Temps de décision



Conformité (*compliance*) - sur-, sous-, appropriée




nombre de fois où la décision finale de la personne
= la recommandation de l'IA / nombre total de
décisions

Une petite remarque concernant les logs comportementaux

Il est toujours intéressant à consulter, mais ne déclarez pas que vous avez mesuré la confiance !

Temps de décision

B.



Conformité (*compliance*) - sur-, sous-, appropriée

Reliance - sur-, sous-, appropriée

nombre de fois où la personne a décidé de consulter les recommandations de l'IA / nombre total de décisions

Une petite remarque concernant les logs comportementaux

Il est toujours intéressant à consulter, mais ne déclarez pas que vous avez mesuré la confiance !

+


Niveaux de questionnement

Nombre de fois où la personne pose des questions complémentaires à propos d'une recommandation de l'IA

Force de l'(dés)accord

Fort accord : accepté rapidement + 0 question supplémentaire

Faible désaccord : réfléchi longtemps + plusieurs questions supplémentaires




Une petite remarque concernant les logs comportementaux

Il est toujours intéressant à consulter, mais ne déclarez pas que vous avez mesuré la confiance !

+

Taux de changement (*switch ratio*)

nombre de fois où la décision initiale $\neq$ décision finale / nombre total de décisions




Une petite remarque concernant les logs comportementaux

Il est toujours intéressant à consulter, mais ne déclarez pas que vous avez mesuré la confiance !

Ce que les gens disent (analyse sémantique)

Comment les gens le disent (analyse vocale)

Pour plus de détails : “*Measure and Manage Trust in Human-AI Conversations*” by Dr. Mengyao Li



<https://research.gatech.edu/ipat/Measure-and-Manage-Trust-in-Human-AI-Conversations>

Récapitulatif : méthodes de collecte de données sur la confiance

Confiance = attitude (mais les logs comportementaux $\approx$ intéressants)

⇒ Entretiens, questionnaires, think aloud

- ! Compromis entre informativité et réalisabilité

- ! Inclure des questions sur compétence, bienveillance, intégrité

Comment mesurer la confiance Humain-AI ?

Scénario:



les participant.e.s ne puissent pas accomplir la tâche seul.e.s

il y ait des conséquences réelles / quelque chose en jeu

Confiance = l'attitude qui consiste à croire qu'un agent aidera un individu à atteindre ses objectifs dans une situation caractérisée par l'**incertitude et la vulnérabilité** (Lee and See, 2004)

Quelles informations veut-on avoir sur la confiance ?



Avant: confiance fondée sur les
expériences et les connaissances
antérieures



avant

Quelles informations veut-on avoir sur la confiance ?

Après: confiance basée sur l'**interaction**
avec le système, mais nous ne savons
pas quelle était la **base** de départ





après

Quelles informations veut-on avoir sur la confiance ?

Avant et après: changement dans la confiance **dû à l'interaction** avec le système




avant



après

Quelles informations veut-on avoir sur la confiance ?

En continu : la **dynamique** de la confiance = ce qui l'influence réellement, comment et dans quelle mesure.



en continu

Récapitulatif : évaluation de la confiance

Confiance = attitude (mais les logs comportementaux $\approx$ intéressants)

⇒ Entretiens, questionnaires, think aloud

! Compromis entre informativité et réalisabilité

! Inclure des questions sur compétence, bienveillance, intégrité

! Avant, après, pendant l'interaction : cela modifie ce que nous enregistrons

Un environnement approprié pour activer la confiance :

scénario **difficile** à résoudre (incertitude)

et qui a des **conséquences** significatives (vulnérabilité)

Récapitulatif : évaluation de la confiance

Confiance = attitude (mais les logs comportementaux $\approx$ intéressants)



→ Entretiens, questionnaires, think aloud

! Compromis entre informativité et réalisabilité

! Inclure des questions sur compétence, bienveillance, intégrité



! Avant, après, pendant l'interaction : cela modifie ce que nous enregistrons

Un environnement approprié pour activer la confiance :

scénario **difficile** à résoudre (incertitude)


et qui a des **conséquences** significatives (vulnérabilité)



Quels facteurs impactent la confiance en l'IA ?

Transparence

↑ Compréhension de l'IA - ↑ capacité à évaluer la qualité de l'IA




Quels facteurs impactent la confiance en l'IA ?

Transparence

! ↑ Compréhension de l'IA ! - ↑ capacité à évaluer la qualité de l'IA

Nuance : transparence sociale




Quels facteurs impactent la confiance en l'IA ?

Performance

↑ Performance de l'IA - ↑ capacité à évaluer la qualité de l'IA

! ↓ Performance de l'IA - = capacité à évaluer la qualité de l'IA

Nuance : performance relative




Quels facteurs impactent la confiance en l'IA ?

Anthropomorphisme

! ↑ Similarité avec les humains ! - ↑ savoir à quoi s'attendre

Nuance : type de contexte et système




Quels facteurs impactent la confiance en l'IA ?

Facteurs liés aux humains :

L'expertise dans les tâches

La confiance en soi



Quels facteurs impactent la confiance en l'IA ?


Facteurs liés à l'environnement :

Terminologie relative à l'« IA »

Terminologie relative au rôle social de l'IA

+images

Le lien avec l'équipe qui a développé l'IA





Réflexion sur les facteurs influençant confiance H-AI

1. Système

Quel est l'aspect du système qui est **crucial** pour la confiance des utilisateurs ?

Pourquoi pourrait-il ne **pas avoir d'impact** sur la confiance des utilisateurs ?

2. Humain

Dans quelle mesure êtes-vous susceptible de rencontrer des **utilisateurs trop confiants ou manquant de confiance en eux** ?

Auraient-ils **besoin** de types d'explications, de styles de communication ou de fonctionnalités **différents** ?

3. Environnement

Quelle **terminologie** utiliseriez-vous pour décrire le système aux utilisateurs ?

Si vous deviez créer une **image** pour représenter votre système dans le cadre d'une présentation commerciale, que représenterait-elle ?

Aller au-delà du 1-1

- Interaction groupe-IA



Aller au-delà du 1-1

- L'interaction peut avoir un impact sur d'autres personnes (*decision subjects*) qui ne peuvent pas interagir avec le système

⇒ Comment les inclure dans la boucle human-AI ?

