

Human–AI Interaction — Séance 1

Pourquoi l'interaction humain–IA est le cœur du sujet

François Bouchet - LIP6 / Sorbonne Université

Cours HAI | Master AI2D


25 septembre 2025

Séance 1A :
philosophie générale, positionnement et premières intuitions

Concevoir des IA qui font **gagner l'équipe humain + IA**

- Objectif du cours : **$H+IA > \max(H, IA)$** *sans* créer de nouveaux risques.
- Trois thèses : **mesurer l'équipe, concevoir pour le doute, journaliser pour apprendre.**
- Format : 14×4h, projet avec *proto* léger (WoZ possible) + dossier, notebook d'analyse & soutenance.

On mesure l'équipe (Team Uplift)



- **Team Uplift** : gain de % de décisions correctes (ou score) de H+IA vs le meilleur des deux.
- **Appropriate Reliance** : suivre l'IA quand elle a raison, s'en écarter quand elle a tort.
- **On n'évalue pas** "l'IA seule" : on évalue le **duo** et le **contrat d'interaction**.

Sondage express (2 min)

- Dans quels cas préférez-vous **H seul** / **IA seule** / **H+IA** ?
- Exemples : triage médical, correction de copies, modération, aide à la programmation, conduite.

Consigne

Voter pour chaque scénario. Soyez prêt à indiquer *pourquoi*.

Acronymes & périmètres

HAI — *Human-AI Interaction*

Interaction entre humains et systèmes d'IA : UI, signaux, **incertitude**, explications, **override**, **abstention**, droit de correction, mesures d'usage.

Exemples : quand expliquer ? comment afficher le doute ? comment journaliser l'action humaine ?

HCAI — *Human-Centered AI*

Cadre socio-technique et la **gouvernance** de l'IA : valeurs, **RGPD/AI Act**, risques, audits, post-market monitoring, organisation.

Exemples : bases légales, AIPD ^a, minimisation, rétention, responsabilités.

a. Analyse d'Impact sur la Protection des Données

xAI — *Explainable AI*

xAI = techniques pour **rendre compréhensibles** les sorties d'un modèle (globalement ou localement) **par un humain (lequel ?)** pour **mieux décider ou auditer**.

HAI vs HCAI : périmètres complémentaires

HAI (focus cours)

- Contrats d'interaction (expliquer, douter, reprendre)
- Design & prototypes (WoZ), **logs** d'usage
- **Évaluer l'équipe** H+IA (Uplift, AR)

HCAI (support)

- Conformité (RGPD, AI Act), AIPD bref
- Éthique & équité (mesure, mitigation)
- Processus d'audit & **monitoring**


On ne peut pas faire du HCAI sérieux sans HAI solide : pas de gouvernance crédible sans interfaces qui exposent l'incertitude, contrats d'interaction, et mesures d'usage pour produire les preuves

HAI $\leftrightarrow$ HCAI : aller-retour nécessaire

- Afficher l'**incertitude** $\Rightarrow$ définir **quand** et **comment** (HAI) + **loguer** ce qui est montré (HCAI).
- Permettre l'**override** $\Rightarrow$ tracer qui/quoi/quand (HCAI) + **rendre visible** à l'utilisateur (HAI).
- Explications **actionnables** $\Rightarrow$ mesurer l'**effet comportemental** (HAI) + documenter (HCAI).

Neats vs. Scruffies — deux traditions en IA

« **Neats** » (symbolique, règles, preuves)




Ex : systèmes experts (années 80), logique formelle

Forces : traçabilité, garanties

Faiblesses : élicitation

Le pendule a oscillé plusieurs fois ; aujourd'hui, HAI vise la **complémentarité**

« **Scruffies** » (heuristiques, apprentissage)



Ex : connexionnisme, ML/DL

Forces : performance, couverture

Faiblesses : effets de bords, surprises

Neats vs. Scruffies — deux traditions en IA

Robert Kowalski

“The analysis of an algorithm A into a logic component L , which defines the logic of the algorithm, and a control component C , which specifies the manner in which the definitions are used, symbolically by the equation $A = L + C$.”

Kowalski, R. (1979). Algorithm = logic + control. Communications of the ACM, 22(7), 424-436.

Rodney Brooks

“it often becomes easier to use the world as its own model, and sense the pertinent aspects of the world when it is necessary. This is a good idea as the world really is a rather good model of itself.”

Brooks, Rodney. (1998). How to Build Complete Creatures Rather than Isolated Cognitive Simulators.


Russell & Norvig

2003 (2nd ed.) : “the victory of the neats (...) over the scruffies”

2021 (4th ed.) : “We focus more on machine learning rather than hand-crafted knowledge engineering”



Systèmes experts : l'éllicitation, talon d'Achille et "2e hiver de l'IA"

- Interaction typique : l'humain **alimente** le système en règles ; **peu de feedback** inverse.
- Limites : difficile d'extraire la connaissance tacite (coûteux, incomplet, fragile aux bords de domaine), passage à l'échelle, hypothèse de monde fermé.



ML/DL : la revanche des données

- Données massives $\Rightarrow$ **performances** élevées sur de nombreuses tâches.
- Tentation : **sortir l'humain de la boucle** ("les données se suffisent à elles-mêmes").
- Risque : erreurs **socialement choquantes** (contrainte métier évidente ignorée), perpétuant des biais historiques¹



LLM & IA générative : interaction inéluctable

- Dialogue, co-édition, **initiative mixte** : l'humain *et* l'IA se répondent.
- Besoin de **contrats d'usage** : quand faire confiance, quand vérifier, quand s'abstenir.
- Besoin d'approches mixtes

ChatGPT 5 ▾

How many times does digit 1 appear from 1 to 1000?

Let's compute carefully, digit by digit.

We want the total number of occurrences of the digit 1 in all numbers from 1 to 1000 (inclusive).

Step 1. Range 1 to 999

We treat the numbers as **three-digit slots** (hundreds, tens, units), padding with zeros if needed (001 ... 999).

- **Units place:** Out of every 10 numbers, 1 ends with a **1**.
→ $999 \div 10 = 99$ full cycles, each contributes 1 occurrence.
→ 99 occurrences, plus 1 extra at 999 → **100 total**.
- **Tens place:** Out of every 100 numbers, 10 have a **1** in the tens place (10–19, 110–119, etc.).
→ $999 \div 100 = 9$ full cycles, each with 10 occurrences.
→ 90 occurrences, plus 10 extra in 910–919 → **100 total**.
- **Hundreds place:** Out of every 1000 numbers, 100 have a **1** in the hundreds place (100–199).
→ Only once in 1–999, so **100 total**.

So from 1 to 999 we have:

$$100 + 100 + 100 = 300$$

Step 2. Add the number 1000

1000 has no **1**, so contributes **0**.

✅ **Final Answer:** The digit 1 appears 300 times from 1 to 1000.

Erreurs “évidentes pour l’humain”

- Conflits d’unités, contraintes réglementaires, conventions métier.
- Explications “belles” mais **non actionnables**.
- **Message** : les **connaissances humaines** sont **complémentaires**, pas de simple “bruit”.


Trois cas concrets (éducation, santé, conduite)

- Alerte prioritaire étudiant mal calibrée (sur-confiance).
- Suggestion de diagnostic sans contexte clé (allergie/contre-indication).
- Aide à la conduite avec modes cachés (surprise d'automatisation).

Pilots 'completely in the dark' on 737 control override lack

Boeing did not prominently warn pilots of the change, which may have contributed to a deadly crash.

By Craig Timberg, Aaron Gregg and Ashley Halsey III The Washington Post
Thursday, November 29, 2018 1:49pm | BUSINESS



Mais aussi plus récemment : <https://dawnproject.com/wp-content/uploads/2025/06/Footage-of-The-Dawn-Projects-live-Austin-safety-tests.mp4?id=0>

Réflexion (3 min)




Question

Citez une erreur IA “choquante” dans votre domaine. Quel **signal** d’interface aurait aidé ?

- 1 min réflexion individuelle 1 min en binôme 1 min restitution.

Fisher, Doll & Hill ; Tukey : leçon d'humilité

- Causalité vs corrélation :
controverse tabac $\Rightarrow$
**protocoles, preuves
accumulées.**
- Tukey : **Exploratory Data
Analysis** — regarder les
données “comme elles sont”.
- Pour HAI : **pré-enregistrer,
mesurer proprement, rester
humble, s'adapter au risque.**



L'histoire complète :

<https://priceconomics.com/why-the-father-of-modern-statistics-didnt-believe/>

Mini-quiz (2 min)

Consigne

Corrélation $\neq$ causalité^a : que **montrer** à l'utilisateur pour **éviter la sur-conviction** ?

a. <https://www.tylervigen.com/spurious-correlations>

“Ironies of automation”

- Plus on automatise, plus l'humain gère les **exceptions** critiques.
- Compétence **dormante** $\Rightarrow$ risque **d'effondrement** en cas d'alerte.
- Concevoir des **garde-fous** : reprise en main, confirmations, délais, “pause”.

Automatisation surprise : quand le système agit “tout seul”

- Modes cachés, auto-corrections silencieuses, seuils implicites.
- **Principe** : pas d'action silencieuse **sur des décisions sensibles**.
- Exposer : **ce que fait l'IA, pourquoi, avec quelle confiance**.

Assistance robuste vs autonomie fragile

- Analogies : ADAS (aide) vs conduite autonome (remplacement).
- **Assistance** = transparence, **abstention**, **override** ; **autonomie fragile** = surprise.
- Notre cap : **assistance qui améliore H+IA**, mesurée et **sécurisée**.

Débat express (4 min) : Faut-il “cacher” l'IA si elle est imparfaite ?

Pour

- Simplicité
- Éviter la défiance

Contre

- Surprise & risques
- Perte d'apprentissage

Conclusion

Concevoir pour le doute : rendre visible l'incertitude, offrir override/abstention, tracer.

Si l'IA était parfaite... (spoiler : non)

- Parfait $\Rightarrow$ pas de feedback ni de logs. **Dans la vraie vie** : on **journalise** pour **améliorer**, **détecter**, **expliquer**.
- Culture avionique & santé : **piste d'audit**, **apprentissage continu**, **retours d'incidents**.



- **Logs horodatés**, versions (modèle/données/UI), **golden set**, **post-market monitoring**.
- Ex. pharmacovigilance : signaler, agréger, **réagir** (*adverse event reporting*).

Schéma minimal de trace (teaser)

Champs	Description
timestamp	ISO8601
session_id	Pseudonyme (UUID)
trial_id	Id d'essai (int)
condition	H_only H_plus_IA IA_only
ai_output	shown none
ai_uncertainty	low mid high na
explanation_variant	off factors contrastive na
human_action	accept override ignore
user_confidence_0_100	[0..100] (si demandé)
correct	Y N (si oracle)
decision_time_ms	Temps de décision
notes	Court texte (optionnel)

Exercice (5 min) : 3 événements à loguer

Consigne

Par deux : listez **3 événements** à journaliser pour votre idée (affichage d'incertitude ? explication ? action humaine ?).

Des incidents aux principes

- Des échecs retentissants $\Rightarrow$ **équité, transparence utile, redevabilité.**
- Notre approche : **mesurer, expliquer pour agir, corriger et apprendre.**

Expliquer $\neq$ convaincre

- On vise l'**action juste**, pas la “satisfaction”.
- Tester **OFF vs ON** (facteurs / contrastif) : l'utilisateur **agit-il mieux** ?

Incertitude visible + “que faire maintenant”

- Badge **Confiance** : faible/moyenne/élevée.
- **Trois facteurs** max (chips) + **exemple contrastif**.
- Ligne “**Que faire ?**” (vérifier X, demander Y, s'abstenir).

- Corriger → apprendre → réévaluer.
- Qualité d'annotation, **golden set**, **accord inter-annotateurs**.
- **Garde-fous** : pas d'auto-application silencieuse, canary/shadow, rollback.

Mesures clés (teaser)

- **Team Uplift** (succès d'équipe)
- **Appropriate Reliance**
- **Erreurs à haute confiance**
- **Calibration** (cohérence confiance/justesse)

3 thèses à retenir

- ① **Mesurer l'équipe H+IA**
- ② **Concevoir pour le doute** (incertitude, override, abstention)
- ③ **Journaliser pour apprendre** (améliorer, détecter, expliquer)

S1B (atelier)

Fiche 2-3 pages (*pré-enregistrement v0*) + **écran clé**.

Séance 1B :
éléments d'aide pour la fiche v0