

Human-AI Interaction — Séance 5b

Protocoles d'évaluation & expérimentation contrôlée

François Bouchet - LIP6 / Sorbonne Université

Cours HAI | Master AI2D

23 octobre 2025

Rappels : Bases de l'expérimentation contrôlée

Pourquoi ces rappels ?

Contexte :

- Concepts vus en IHM en M1 (plans expérimentaux, randomisation, hypothèses)
- Aujourd'hui : **rappels rapides** + focus sur l'**application HAI**

Objectifs de cette partie :

- Formaliser une **question de recherche** HAI
- Choisir un **plan expérimental** adapté
- Identifier et contrôler les **variables confondantes** (facteurs de confusion)

Exemple fil rouge : D&D (D&D) testent leur assistant IA pour TP de programmation (L1, débogage Python).

Poser la bonne question

Exemple D&D :

- **Domaine** : Enseignement programmation (L1 info, débogage Python).
- **Contexte** : Étudiants doivent corriger du code avec erreurs (syntaxe, logique, exceptions).
- **Intervention** : Assistant IA propose des *hints* (corrections suggérées).

Question de recherche (RQ) :

« L'assistant IA améliore-t-il la réussite des exercices de débogage sans créer de dépendance excessive ? »

Hypothèses :


- H_0 (nulle) : Pas de différence de taux de réussite entre H_{only} et $H_{\text{plus_IA}}$
- H_1 (alternative) : $H_{\text{plus_IA}}$ améliore le taux de réussite

Variables & métriques

Variables :

- **Variable indépendante (VI)** : $condition \in \{H_only, H_plus_IA\}$
- **Variable dépendante primaire (VD)** : `correct` (exercice résolu correctement, binaire Y/N)
- **VD secondaires** : `decision_time_ms`, `user_confidence`, métriques HAI (reliance, calibration...)

Schéma causal simplifié :



Plans expérimentaux : *between* vs *within* subjects

Between-subjects : chaque participant ne voit qu'une condition

- ✓ Pas d'effet d'ordre, pas d'apprentissage lié à répétition
- ✗ Besoin de randomisation stricte, plus de participants
- **Exemple D&D** : 50 étudiants H_only, 50 étudiants H_plus_IA (randomisation sur session_id)

Within-subjects : chaque participant passe par toutes les conditions

- ✓ Moins de participants, contrôle des différences individuelles.
- ✗ Effet d'ordre, fatigue, **apprentissage entre conditions** → contrebalancement obligatoire
- **Attention HAI/apprentissage** : L'étudiant s'améliore naturellement → variable confondante majeure !

Randomisation & variables confondantes

Randomisation : assignment aléatoire à un groupe, garantissant groupes équivalents *en moyenne* sur les variables non observées.

- **Simple** : assignation aléatoire 50/50 (ex : pile/face sur `session_id`)
- **Stratifiée** : si facteur important connu, forcer l'équilibre entre groupes

Variable confondante classique en HAI éducatif :

Si les étudiants ayant déjà fait du Python sont surreprésentés dans `H_plus_IA` → on ne peut pas isoler l'effet IA de l'effet expertise → besoin de stratifier et de vérifier

Vérification dans les logs :

Comparer la distribution de `slice_id` (novice/expert) entre les deux conditions¹

Objectif : s'assurer que chaque groupe a environ la même proportion de novices et d'experts

1. On verra comment le tester statistiquement en partie 2

Transition : Et maintenant ?

Récapitulatif :

- RQ claire + H_0/H_1 *avant* de collecter les données
- Plan expérimental choisi (*between* recommandé ici)
- Randomisation pour contrôler les variables confondantes

Question suivante :

Une fois les données collectées, **comment décide-t-on quel test statistique utiliser ?**

Tests statistiques : boîte à outils

Qu'est-ce qu'un test statistique ?

Logique du test :

- 1 **Hypothèse nulle (H_0)** : "Il n'y a pas d'effet" (ex : même réussite H_{only} et $H_{\text{plus_IA}}$)
- 2 **Hypothèse alternative (H_1)** : "Il y a un effet" (ex : réussite($H_{\text{plus_IA}}$) > réussite(H_{only}))
- 3 **Statistique de test** : nombre calculé à partir des données qui résume la différence observée²
- 4 **Distribution sous H_0** : si H_0 vraie, quelle est la distribution de cette statistique ?
- 5 **p-value** : probabilité d'observer une différence $\geq$ celle observée **si H_0 est vraie**
- 6 **Décision** : si $p < \alpha$ (souvent 0.05), on rejette H_0
 $\Rightarrow$ **attention** à l'interprétation : ce n'est pas une preuve que H_0 est fausse !

Erreurs possibles

	H_0 vraie	H_0 fausse
Rejeter H_0	Erreur Type I (faux positif)	Bonne décision
Ne pas rejeter H_0	Bonne décision	Erreur Type II (faux négatif)

Contrôle des erreurs :

- **Type I** : contrôlé par α (ex : $\alpha = 0.05 \rightarrow 5\%$ de faux positifs).
- **Type II** : contrôlé par la **puissance** (typiquement $0.80 =$ probabilité de détecter un effet s'il existe). La puissance dépend de la taille d'échantillon (n) et de la taille d'effet. On verra comment dimensionner n en Partie 7 (bonus).

Exemple D&D

Données observées :

- H_{only} : 65% de réussite (33/50 exercices résolus).
- $H_{\text{plus_IA}}$: 78% de réussite (39/50 exercices résolus).
- Différence : +13 points de pourcentage.

Question : effet du hasard ou de l'IA ?

Test statistique :

- H_0 : réussite identique dans les deux groupes.
- Test approprié : χ^2 (variable binaire, 2 groupes indépendants).
- Résultat : $p = 0.018$.

Interprétation :

Probabilité d'observer ≥ 13 pp de différence si H_0 vraie = 1.8%.

$\Rightarrow$ On rejette H_0 , l'IA semble améliorer la réussite.

Bibliothèques Python pour tests statistiques :

scipy.stats :

- Bibliothèque standard pour calculs statistiques
- ✓ Large couverture (distributions, tests, corrélations)
- ✗ Syntaxe parfois technique, sorties minimalistes

pingouin :

- Surcouche simplifiée de scipy.stats
- ✓ Syntaxe plus claire, sorties enrichies (taille d'effet, IC, tableaux formatés)
- ✗ Moins exhaustif que scipy (ex : pas de Fisher exact)

Recommandation pour le projet :

Privilégier **pingouin**, mais utiliser **scipy.stats** si besoin d'un test absent de pingouin

Plans expérimentaux : indépendance vs appariement

Indépendance (between-subjects) :


- Chaque participant dans un seul groupe
- Groupes distincts, pas de lien entre observations
- **Tests associés** : χ^2 , t-test indépendant, Mann-Whitney

Appariement (within-subjects, mesures répétées) :

- Même participant testé dans plusieurs conditions
- Observations liées (pré-test/post-test, A/B sur même personne)
- **Tests associés** : McNemar, t-test apparié, Wilcoxon

Dans ce cours : focus sur **between-subjects** (recommandation projet).
Les tests appariés existent mais ne seront pas détaillés.

Arbre de décision : choisir le bon test



En **rouge** : tests statistiques. Fond gris : tests existants mais non détaillés.

Tests pour variables binaires

Situation : comparer une VD binaire (ex. : correct Y/N) entre 2 groupes indépendants

Test du χ^2 :

- Compare les fréquences observées vs attendues sous H_0
- **Hypothèse** : effectifs attendus ≥ 5 par cellule
- **Python** : `pingouin.chi2_independence()`

Test exact de Fisher :

- Alternative si effectifs < 5 (petits échantillons)
- Calcul exact (pas d'approximation)
- **Python** : `scipy.stats.fisher_exact()` (pas dans pingouin)

Exemple HAI : réussite H_only vs H_plus_IA $\rightarrow$ table de contingence $2 \times 2 \rightarrow \chi^2$

Exemple : table de contingence

D&D — Test réussite :

Table de contingence 2×2 :

Condition	Réussi	Échoué	Total
H_only	33	17	50
H_plus_IA	39	11	50
Total	72	28	100

Application du χ^2 :

- On construit la table : condition (lignes) $\times$ réussite (colonnes)
- On calcule $\chi^2 = \sum \frac{(O-E)^2}{E}$ (observé vs attendu sous H_0)
- Résultat : $\chi^2 = 5.56$, $p = 0.018$

Tests pour variables continues (2 groupes)

Situation : comparer une VD continue (ex. : `decision_time_ms`) entre 2 groupes indépendants

t-test de Student :

- Compare les moyennes de deux groupes
- **Hypothèses** : normalité, homoscedasticité (variances égales)
- Si variances inégales : **Welch's t-test** (plus robuste)
- **Python** : `pingouin.ttest()` (choisit Student ou Welch selon homoscedasticité)

Mann-Whitney U (test non-paramétrique) :

- Alternative si normalité violée ou distribution asymétrique
- Compare les **rangs** (médianes), pas les moyennes
- Plus robuste, moins puissant si normalité vraie
- **Python** : `pingouin.mwu()`

Tests pour corrélations

Situation : mesurer la relation entre deux variables continues (ex. : `user_confidence` × `correct`).

Corrélation de Pearson :

- Mesure la **relation linéaire** (par hypothèse)
- Coefficient $r \in [-1, 1]$: -1 = anticorrélation parfaite, 0 = aucune, 1 = corr. parfaite
- **Python** : `pingouin.corr(method='pearson')`

Corrélation de Spearman :

- Mesure la **relation monotone** (relation d'ordre, pas forcément linéaire)
- basée sur les rangs (non-paramétrique) donc plus robuste aux outliers
- **Python** : `pingouin.corr(method='spearman')`

Test de significativité :

- On teste $H_0 : r = 0$ (pas de corrélation).
- Si $p < 0.05$, on rejette H_0 (corrélation significative).

Exemple : calibration (corrélation)

D&D — Calibration :

Question : La confiance de l'étudiant est-elle alignée avec sa réussite ?

Variables :

- `user_confidence` : confiance déclarée (continue, 0-1)
- `correct` : réussite (binaire, 0/1)

Choix du test :

On utilise **Spearman** car :

- `correct` est binaire $\rightarrow$ relation pas linéaire
- On mesure : “confiance élevée $\rightarrow$ plus de chance de réussite” (monotone)

Résultats :

- `H_only` : $r_s = 0.42$, $p = 0.003$ (corrélation significative)
- `H_plus_IA` : $r_s = 0.28$, $p = 0.04$ (corrélation plus faible mais significative)

Décision pratique : quel test choisir ?

Règles empiriques :

- **VD binaire** (ex. : correct) $\rightarrow \chi^2$ (ou Fisher si petits effectifs)
- **VD continue, 2 groupes, normalité OK** $\rightarrow$ t-test
- **VD continue, 2 groupes, normalité douteuse** $\rightarrow$ Mann-Whitney
- **VD continue, 2+ groupes** $\rightarrow$ ANOVA (ou Kruskal-Wallis si non-normal)
- **2 variables continues** $\rightarrow$ Pearson (linéaire) ou Spearman (monotone)

Vérifier les hypothèses :

- **Normalité** : histogramme, QQ-plot, Shapiro-Wilk
- **Homoscédasticité** : Levene's test
- Si $n > 30$, t-test généralement robuste, **sauf** si distribution très asymétrique (outliers extrêmes) $\rightarrow$ privilégier Mann-Whitney ou log-transform

Taille d'effet : p -value $\neq$ importance

Problème :

Avec un échantillon large, même un écart très faible peut être statistiquement significatif

Exemple :

Avec $n = 10\,000$ par groupe, une différence de 1 pp (75% vs 76%) peut donner $p < 0.05$, mais est-ce **pratiquement pertinent** ?

Taille d'effet : mesure standardisée de la magnitude

- **Cohen's d** (t-test) : $d = \frac{\text{mean}_1 - \text{mean}_2}{\text{combined_std}}$
 - Petit : 0.2 Moyen : 0.5 Large : 0.8
- **Cramér's V** (χ^2) : $V = \sqrt{\frac{\chi^2}{n \times \text{df}}}$
 - Petit : 0.1 Moyen : 0.3 Large : 0.5

Intervalle de confiance 95%

Définition :

Fourchette plausible de l'effet³ (ex : différence de moyennes)

Interprétation :

Si IC inclut 0, l'effet n'est pas significatif (la différence pourrait être nulle)

Exemple :

- Différence de moyennes : 50 ms
- IC 95% : [10 ms, 90 ms] → significatif (ne touche pas 0)
- IC 95% : [-20 ms, 120 ms] → non significatif (inclut 0)

Avantage :

Donne une idée de la **précision** de l'estimation (IC large = incertitude élevée).

3. La formule dépend de l'effet considéré (d , $V...$) : on s'épargne les formules ici

Exemple : interprétation complète

D&D — Test réussite :

- H_{only} : 65% (33/50) vs $H_{\text{plus_IA}}$: 78% (39/50)
- Test : χ^2 , $p = 0.018$
- Taille d'effet : Cramér's $V = 0.24$ (effet moyen)
- IC 95% : [0.05, 0.43].

Interprétation :

- **Statistiquement significatif** : $p < 0.05 \rightarrow$ on rejette H_0 .
- **Effet moyen** : $V = 0.24$ (entre 0.1 et 0.3)
- **IC ne touche pas 0** : effet robuste
- **Pratiquement pertinent ?** +13 pp de réussite $\rightarrow$ oui, mais à quel coût (développement, overreliance) ?

Transition : Et les métriques HAI spécifiques ?

Récapitulatif :

- Logique du test : H_0/H_1 , p -value, erreurs Type I/II
- Arbre de décision : choisir le bon test selon le type de VD et la question de recherche
- Taille d'effet et IC : ne pas s'arrêter à $p < 0.05$

Question suivante :

On sait tester la **réussite**, mais en HAI, quelles autres **métriques** doit-on mesurer ?

Métriques HAI spécifiques

Au-delà de la réussite brute

Problème :

Mesurer uniquement la **réussite** (accuracy) ne suffit pas en HAI

Exemple D&D :

- Réussite : $H_{\text{only}} = 65\% \rightarrow H_{\text{plus_IA}} = 78\%$ (+13 pp)
- **Mais** : Comment l'IA affecte-t-elle la **métacognition**, l'**autonomie**, la **confiance** ?

Enjeux spécifiques en contexte éducatif :

- **Overreliance** : dépendance excessive (copier-coller aveugle)
- **Dégradation de la calibration** : confiance mal alignée avec réussite
- **Apprentissage à long terme** : l'IA aide-t-elle vraiment à apprendre ?

Objectif de cette partie : définir et mesurer les **métriques HAI**

Tableau récapitulatif des métriques HAI

Métrique	Définition	Calcul (logs)	Interprétation
Réussite	Taux de décisions correctes	<code>correct == 'Y' / total</code>	Baseline : performance sans IA
Appropriate reliance	Accepter IA quand correcte, ignorer quand incorrecte	<code>(accept ^ correct=Y) + (override ^ correct=N) / total</code>	Reliance calibrée
Calibration	Corrélation confiance × réussite	<code>Spearman user_confidence × correct</code>	Métacognition
Erreurs haute confiance	<code>correct=N ^ user_confidence > 0.8</code>	<code>Count + rate</code>	Dangereux (surconfiance)
Temps de décision	Temps entre hint et action	<code>decision_time_ms</code> (médiane, IQR)	Effcience vs réflexion
Taux abstention IA	<code>abstained=true / total hints</code>	<code>Count</code>	Fallback vers humain
Taux override	<code>human_action=override / total hints</code>	<code>Count</code>	Autonomie préservée ?

Métrique 1 : Réussite (accuracy)

Définition :

Taux d'exercices résolus correctement

Calcul :

$$\text{Accuracy} = \frac{\text{Nombre de correct=Y}}{\text{Total d'exercices}}$$

Test statistique :

χ^2 pour comparer les taux entre H_only et H_plus_IA

Exemple D&D :

- H_only : 65% (33/50)
- H_plus_IA : 78% (39/50)
- χ^2 , $p = 0.018$, Cramér's $V = 0.24$ (effet moyen)

Limite : Ne dit rien sur **comment** l'IA est utilisée (reliance, autonomie)

Métrique 2 : Appropriate reliance

Définition :

L'utilisateur accepte l'IA quand elle a raison, et la corrige (override) quand elle a tort

Calcul :

$$\text{Appropriate reliance} = \frac{(\text{accept} \wedge \text{correct}=\text{Y}) + (\text{override} \wedge \text{correct}=\text{N})}{\text{Total avec hint IA}}$$

Interprétation :

- Score élevé (proche de 1) : reliance **calibrée**
- Score faible : soit **overreliance** (accepte aveuglément), soit **underreliance** (rejette systématiquement)

Exemple D&D :

- H_plus_IA : appropriate reliance = 0.68 (68% de bonnes décisions sur les hints)
- **Problème détecté** : 25% des hints incorrects acceptés sans correction (overreliance)

Métrique 3 : Calibration (confiance – cf. S3)

Définition :

Corrélation entre la confiance déclarée de l'utilisateur et sa réussite effective

Calcul :

Corrélation de Spearman entre `user_confidence` (0-1) et `correct` (0/1)

Interprétation :

- $r_s \approx 1$: parfaite calibration (confiance = probabilité de réussite)
- $r_s \approx 0$: pas de calibration (confiance déconnectée de la réussite)
- $r_s < 0$: calibration inverse (confiant quand faux, pas confiant quand correct)

Exemple D&D :

- `H_only` : $r_s = 0.42$, $p = 0.003$ (calibration correcte)
- `H_plus_IA` : $r_s = 0.28$, $p = 0.04$ (dégradation significative)

Enjeu éducatif : Calibration = **métacognition** (savoir ce qu'on sait)

Métrique 4 : Erreurs haute confiance

Définition :

Décisions incorrectes avec confiance élevée ($\text{correct}=\text{N} \wedge \text{user_confidence} > 0.8$)

Calcul :

$$\text{Taux erreurs haute confiance} = \frac{\text{Nombre de } (\text{correct}=\text{N} \wedge \text{user_confidence} > 0.8)}{\text{Total d'exercices}}$$

Interprétation :

- **Dangereux en contexte éducatif** : étudiant sûr de lui mais faux $\rightarrow$ pas de révision
- Indicateur d'**surconfiance** (biais cognitif, on y reviendra en S6).

Exemple D&D :

- H_{only} : 8% (4/50 exercices)
- $H_{\text{plus_IA}}$: 18% (9/50 exercices)
- $\chi^2, p = 0.03 \rightarrow$ augmentation significative

Conclusion : L'IA améliore la réussite mais dégrade la métacognition

Métrique 5 : Temps de décision

Définition :

Temps entre l'affichage du hint IA et l'action de l'utilisateur

Calcul : `decision_time_ms` (médiane, IQR)

Interprétation :

- **Temps court** : efficience (bien) **OU** copier-coller aveugle (mal)
- **Temps long** : réflexion approfondie (bien) **OU** confusion (mal)
- → Ambiguïté : il faut croiser avec d'autres métriques (reliance, calibration)

Exemple D&D :

- `H_only` : médiane = 180s, IQR = [120s, 240s].
- `H_plus_IA` : médiane = 120s, IQR = [80s, 160s].
- Mann-Whitney, $p = 0.03$ → différence significative.

Question : Temps plus court = gain d'efficience ou perte de réflexion ?

→ Croiser avec taux d'override (si faible → copier-coller aveugle)

Métriques 6 & 7 : Abstention IA et Override

Taux d'abstention IA :

- **Définition** : `abstained=true` / total hints demandés
- **Interprétation** : IA refuse de suggérer si incertitude haute ou préconditions non remplies
- **Exemple** : 15% d'abstention chez D&D → fallback vers tuteur humain
- **Lien guidelines** : G2 (make clear what system can do), G15 (scope services)

Taux d'override :

- **Définition** : `human_action=override` / total hints affichés
- **Interprétation** : L'utilisateur corrige le hint IA
- **Ambiguïté** :
 - Override élevé + appropriate reliance élevée = **autonomie préservée** (bien)
 - Override faible + appropriate reliance faible = **underreliance** (méfiance excessive) ou **overreliance** (acceptation aveugle)
- **Exemple** : 12% d'override chez D&D → sous-utilisation de l'autonomie ?

Comment calculer et tester ces métriques ?

Métrique	Type de variable	Test statistique
Réussite	Binaire	χ^2 sur condition $\times$ correct
Appropriate reliance	Continue (score 0-1)	t-test ou Mann-Whitney sur score agrégé par participant
Calibration	Corrélation	Spearman par condition, comparer r_s (Fisher z-transform)
Erreurs haute confiance	Binaire	χ^2 sur condition $\times$ erreur_HC
Temps de décision	Continue	Mann-Whitney (souvent asymétrique)
Abstention / Override	Continue (taux)	t-test ou Mann-Whitney sur taux par participant

Principe général :

- Calculer la métrique **par participant** (ou par essai)
- Agréger si nécessaire (ex : moyenne par participant pour appropriate reliance)
- Appliquer le test approprié (cf. Partie 2)

Synthèse : exemple D&D

Résultats complets :

Métrique	H_only	H_plus_IA	Signif. ?
Réussite	65%	78%	$p = 0.018$ (↑)
Appropriate reliance	—	68%	—
Calibration (r_s)	0.42	0.28	$p = 0.04$ (↓)
Erreurs haute confiance	8%	18%	$p = 0.03$ (↑)
Temps de décision (médiane)	180s	120s	$p = 0.03$ (↓)
Taux override	—	12%	—

Conclusion :

- **Bonne nouvelle** : IA améliore la réussite (+13 pp, effet moyen)
- **Mauvaise nouvelle** : Dégradation de la métacognition (calibration ↓, surconfiance ↑)
- **Ambiguïté** : Temps plus court, mais reliance faible → copier-coller aveugle ?

Implications pour le design : besoin de mécanismes pour encourager la réflexion critique (ex : afficher incertitude IA, forcer justification avant acceptance)

Transition : Et les pièges méthodologiques ?

Récapitulatif :

- Métriques HAI : réussite, reliance, calibration, erreurs haute confiance, Temps de décision, abstention, override.
- Comment les calculer et les tester (lien avec Partie 2).
- Exemple D&D : IA améliore réussite mais dégrade métacognition.

Question suivante :

Comment éviter les **pièges méthodologiques** qui invalident les résultats ?

Pièges & rigueur méthodologique

Problème :

Même avec un bon protocole et de bonnes métriques, des erreurs méthodologiques peuvent invalider les résultats

Pièges principaux :

- ❶ ***p*-hacking** : tester jusqu'à trouver $p < 0.05$
- ❷ **HARKing** : formuler les hypothèses après avoir vu les résultats
- ❸ **Cherry-picking des slices** : ne rapporter que les résultats favorables
- ❹ **Variables confondantes non contrôlées** : variables cachées qui biaisent les résultats
- ❺ **Taille d'échantillon insuffisante** : sous-puissance, faux négatifs

Objectif de cette partie : identifier et éviter ces pièges.

Piège 1 : p -hacking

Définition : Tester de multiples hypothèses jusqu'à trouver $p < 0.05$, sans correction

Exemple D&D :

- Ils testent 20 slices différentes : novice/expert, facile/difficile, semaines 1-10, matin/après-midi, etc.
- Trouvent $p = 0.03$ sur “exercice difficile $\times$ expert $\times$ après-midi $\times$ semaine 8”
- **Problème** : Avec 20 tests à $\alpha = 0.05$, on **attend** $20 \times 0.05 = 1$ faux positif même si H_0 vraie partout
- Probabilité d'au moins un faux positif : $1 - (1 - 0.05)^{20} \approx 64\%$

Comment éviter ?

- **Pré-enregistrer** les hypothèses et le plan d'analyse *avant* de voir les données.
- Si tests multiples nécessaires, appliquer une **correction de Bonferroni** :
$$\alpha_{\text{corrigé}} = \frac{0.05}{20} = 0.0025$$

Piège 2 : HARKing

Définition : Hypothesizing **A**fter **R**esults are **K**nown

Exemple D&D :

- Après analyse, ils observent que l'IA fonctionne bien chez les **experts**
- Ils formulent alors H_1 : "L'IA aide particulièrement les experts"
- Ils testent et trouvent $p = 0.04$ chez les experts
- **Problème :** Hypothèse non formulée *a priori*, c'est une **exploration post-hoc**.

Pourquoi c'est problématique ?

- L'hypothèse a été "guidée" par les données $\rightarrow$ inflation du risque de Type I
- On "mine" les données jusqu'à trouver quelque chose de significatif

Comment éviter ?

- **Pré-enregistrer** H_0/H_1 *avant* la collecte de données.
- Distinguer clairement : **analyses confirmatives** (pré-enregistrées) vs **analyses exploratoires** (post-hoc, à interpréter avec prudence).

Piège 3 : Cherry-picking des slices

Définition : Ne rapporter que les résultats favorables, ignorer les autres

Exemple D&D :

- Testent 5 slices : novice, expert, facile, difficile, intermédiaire
- Trouvent effet significatif chez les **experts** ($p = 0.02$) et les **exos difficiles** ($p = 0.04$)
- Ne trouvent rien chez novice ($p = 0.6$), facile ($p = 0.8$), intermédiaire ($p = 0.3$)
- Ils écrivent : “IA efficace pour les experts et les exercices difficiles” → **cherry-picking**

Problème :

On donne une image biaisée (“ça marche”), alors que ça ne marche que dans 2/5 cas

Comment éviter ?

- **Rapporter tous les tests effectués**, même non significatifs
- Définir *a priori* les slices d'intérêt principales (ex : novice vs expert) et secondaires (exploratoires)
- Si tests multiples, corriger (Bonferroni)


Piège 4 : Variables confondantes non contrôlées (1/2)

Définition : Variable non contrôlée qui influence à la fois la VI et la VD

Exemple D&D :

- Randomisation défailante : les **experts Python** sont surreprésentés dans H_plus_IA (60% vs 40% dans H_only)
- Résultat : réussite H_plus_IA = 78% vs H_only = 65%
- **Question** : L'amélioration est-elle due à l'IA ou à l'expertise ?

Schéma causal :



Piège 4 : Variables confondantes non contrôlées (2/2)

Comment éviter ?

- **Vérifier la randomisation** : tableau croisé condition $\times$ slice_id, test χ^2 ($p > 0.05$ attendu : pas de différence entre les conditions)
- Si déséquilibre : **stratification** ou ajustement statistique (régression logistique avec covariable)

Piège 5 : Taille d'échantillon insuffisante (1/2)

Définition :

Échantillon trop petit → **sous-puissance** → risque élevé d'erreur Type II (faux négatif)

Exemple D&D :

- Ils collectent $n = 10$ participants par groupe (au lieu de 50)
- Résultat : réussite 65% vs 78%, mais $p = 0.12$ (non significatif)
- **Question** : Pas d'effet réel ou juste pas assez de données ?

Puissance statistique :

Probabilité de détecter un effet s'il existe (typiquement 0.80)

Piège 5 : Taille d'échantillon insuffisante (2/2)

Comment éviter ?

- **Analyse de puissance *a priori*** : calculer n requis pour détecter l'effet minimal d'intérêt avec puissance 0.80
- **Règle approximative** : pour détecter une différence de 10 pp entre deux proportions (ex : 65% vs 75%) avec puissance 0.80, il faut environ $n \approx 180$ participants par groupe.
- **Outils Python** : `pingouin.power_ttest()`
- Exemple : détecter $\Delta = 10$ pp avec $p = 0.65$, $\alpha = 0.05$, puissance 0.80
→ $n \approx 180$ par groupe

Protocole écrit & pré-enregistrement

Solution transversale à tous les pièges : protocole écrit *avant* collecte de données

Contenu minimal :

- ❶ Question de recherche (RQ)
- ❷ Hypothèses (H_0 , H_1)
- ❸ Plan expérimental (between/within, randomisation, stratification)
- ❹ Variables (VI, VD primaire, VD secondaires)
- ❺ Métriques HAI prévues (réussite, reliance, calibration, etc.)
- ❻ Tests statistiques prévus (quel test pour quelle VD ?)
- ❼ Critère de décision ($\alpha = 0.05$, taille d'effet minimale acceptable)
- ❽ Taille d'échantillon (justifiée par analyse de puissance ou contraintes pratiques)
- ❾ Analyses exploratoires prévues (si oui, méthode de correction)

Avantages :

- **Traçabilité** : évite HARKing, p-hacking
- **Reproductibilité** : autres chercheurs peuvent répliquer
- **Conformité RGPD/AI Act** : accountability, documentation des décisions (cf. S4)

Checklist : protocole expérimental rigoureux (1/2)

Avant la collecte de données :

- ☐ RQ claire et testable ?
- ☐ H_0/H_1 formulées ?
- ☐ Plan expérimental justifié (between/within) ?
- ☐ Randomisation/stratification décrite ?
- ☐ Variables (VI, VD) identifiées ?
- ☐ Métriques HAI définies (accuracy, reliance, calibration, etc.) ?
- ☐ Tests statistiques choisis (arbre de décision appliqué) ?
- ☐ Taille d'effet minimale acceptable définie ?
- ☐ Taille d'échantillon justifiée (analyse de puissance ou contraintes) ?
- ☐ Critère de décision clair (α , correction si tests multiples) ?
- ☐ Protocole écrit (pré-enregistrement) ?

Checklist : protocole expérimental rigoureux (2/2)

Après la collecte de données :

- ☐ Logs conformes au schéma canonique ?
- ☐ Vérification randomisation (crosstab slices) ?
- ☐ Tous les tests rapportés (même non significatifs) ?

Transition : Et dans la vraie vie ?

Récapitulatif :

- 5 pièges : p-hacking, HARKing, cherry-picking, variables confondantes, sous-puissance
- Solution transversale : protocole écrit et pré-enregistrement
- Checklist pour éviter les erreurs

Question suivante :

Comment ces méthodes sont-elles appliquées dans la **recherche HAI réelle** ?

Cas réels : exemples de la littérature HAI

Article : Bansal et al. (2021) — Complémentarité H+IA

Référence : Bansal, G., et al. (2021). *Does the Whole Exceed its Parts? The Effect of AI Explanations on Complementary Team Performance*. CHI.

Contexte :

Tâches de classification (sentiment classification, raisonnement logique LSAT).

Participants : workers MTurk, IA avec accuracy comparable aux humains (84%).

Question de recherche :

Les explications IA peuvent-elles mener à une **performance complémentaire** (équipe H+IA $> \max(\text{H seul}, \text{IA seule})$) ?

Design :

- **Between-subjects**, $n = 200+$ participants sur 3 datasets.
- 4 conditions : H, IA, H+IA sans explication, H+IA avec explication.
- Métriques : accuracy, appropriate reliance, complémentarité.

Résultats clés :

- ✓ **Complémentarité observée** : $H+IA > \max(H, IA)$ dans certaines conditions
- ✗ **Explications n'améliorent PAS la complémentarité**
 - **Effet des explications** : augmentent la probabilité d'accepter la recommandation IA, indépendamment de sa justesse (overreliance)
 - **Condition de complémentarité** : $H+IA$ surpasse H et IA seulement quand leurs erreurs sont **complémentaires** (l'un compense l'autre)

Leçons pour HAI :

- Explications $\neq$ garantie d'appropriate reliance (peuvent augmenter overreliance)
- Complémentarité nécessite design explicite : afficher incertitude IA, encourager réflexion critique
- Pertinent pour code/éducation : si IA confiante $\rightarrow$ copier-coller aveugle (overreliance) ; besoin de mécanismes pour encourager autonomie

Transition : À vous de jouer !

Récapitulatif Parties 1-5 :

- **Partie 1** : Fondations (RQ, plans expérimentaux, randomisation).
- **Partie 2** : Boîte à outils statistiques (tests, taille d'effet, IC).
- **Partie 3** : Métriques HAI (reliance, calibration, erreurs HC).
- **Partie 4** : Pièges (p-hacking, HARKing, variables confondantes, sous-puissance).
- **Partie 5** : Cas réels

Question suivante :

Comment appliquer tout ça en **pratique** ?

→ **Exercices de TME !**