


Interaction Humain-AI : Une approche apprentissage par renforcement

Amel Yessad

November 20, 2025



Processus de conduite de la recherche

Processus à trois étapes : *FORADAPTE* (**FOR**malize, **ADAPT**e and **E**valuate)

Processus de conduite de la recherche

Processus à trois étapes : *FORADAPTE* (**FOR**malize, **ADAPT**e and **E**valuate)

- **FOR**malisation du problème selon l'objectif visé (ex. adapter les feedbacks, modéliser l'utilisateur).

Processus de conduite de la recherche


Processus à trois étapes : *FORADAPTE* (**FOR**malize, **ADAPT**e and **E**valuate)

- **FOR**malisation du problème selon l'objectif visé (ex. adapter les feedbacks, modéliser l'utilisateur).
- **ADAPT**ation des modèles/algorithmes choisis.
 - affiner, justifier et expliquer des choix de modélisation
 - intégrer des connaissances expertes
 - ajuster les paramètres du modèle à partir des données
 - définir des critères d'évaluation

Processus de conduite de la recherche

Processus à trois étapes : *FORADAPTE* (**FOR**malize, **ADAPT**e and **E**valuate)

- **FOR**malisation du problème selon l'objectif visé (ex. adapter les feedbacks, modéliser l'utilisateur).
- **ADAPT**ation des modèles/algorithmes choisis.
 - affiner, justifier et expliquer des choix de modélisation
 - intégrer des connaissances expertes
 - ajuster les paramètres du modèle à partir des données
 - définir des critères d'évaluation
- **E**valuation de l'approche proposée (comparaison avec des baselines, expérimentation en contexte écologique, sur des données simulées, etc.)



Décision adaptative AI-Humain

Boucle d'adaptation

- Une boucle d'adaptation = **Collecte de traces** → **Inférence (modélisation de l'utilisateur)** → **Adaptation (modèle de décision)**
- Objectif : améliorer l'interaction avec les utilisateurs et l'efficacité du système
- Deux types d'adaptation :
 - **Boucle courte (Inner-loop)** : adaptation en temps réel, au sein de l'activité
 - **Boucle longue (Outer-loop)** : adaptation sur la durée, au delà de l'activité

Objectifs du cours


- Comprendre le cadre de décision séquentielle
- Introduire l'apprentissage par renforcement (RL)
- Modéliser une interaction humain-agent AI
- Maximiser une fonction d'utilité pour une tâche donnée

Caractéristiques du problème de la décision en HAI & RL

Exemples de Problèmes : décision du feedback à afficher, décision de la prochaine activité à recommander, ..., en vue de **maximiser la satisfaction de l'utilisateur**, de **minimiser la frustration, l'abandon**, etc. Plusieurs constats :

- **Absence de supervision explicite** : le système apprend à partir de retours indirects de l'environnement (succès, échec, engagement renforcé, baisse de motivation), sans signal supervisé
- **Retours différés** : le signal de récompense peut être différé, rendant difficile le lien entre une action et ses conséquences
- **Dépendance temporelle** : les expériences sont séquentielles et non i.i.d., l'action à l'instant t influence l'état de l'environnement à l'instant $t + 1$ et au-delà
- **Incertitude de l'état observé** : l'agent ne dispose que d'une observation incomplète ou bruitée de l'état réel de l'environnement


Apprentissage par renforcement (RL) : Principe



Apprentissage par renforcement (RL) : Application

IA pour les échecs



- L'IA joue des milliards de parties contre elle-même
- À chaque partie, on récompense les coups de l'IA victorieuse et pénalise ceux de l'IA perdante
- Construit progressivement une base de coups efficaces



Apprentissage par renforcement (RL) : Application

IA pour l'Apprentissage de la lecture

- L'IA donne des aides aléatoirement
- A chaque fois, elle apprend si cela a été utile
- Construit progressivement une politique d'aide



Apprentissage par renforcement (RL) : à la croisée de plusieurs disciplines

- Le RL résulte de la convergence de trois domaines majeurs :
 - **Neurosciences computationnelles** : renforcement des connexions synaptiques (règle de Hebb, modèle de Rescorla & Wagner) (Kawato et al. 2007).
 - **Psychologie expérimentale** :
 - Conditionnement réponsant (Pavlov, Watson) : s'intéresse aux causes du comportement
 - Conditionnement opérant (Skinner) : s'intéresse au comportement influencé par les conséquences; le lien entre action et résultat (récompense/punition)
 - Apprentissage par essais-erreurs (la "boîte à problèmes") (Thorndike 1932)
 - **Programmation dynamique** : travaux de Bellman sur la théorie du contrôle optimal Bellman 1966.
 - Renforcement = critères à maximiser

Environnement ? Processus de décision markovien (MDP)

Un **processus de décision markovien (MDP)** modélise la dynamique d'un environnement (déterministe ou stochastique) contrôlé par un agent.

$$M = (S, A, R, T)$$

où :

Environnement ? Processus de décision markovien (MDP)

Un **processus de décision markovien (MDP)** modélise la dynamique d'un environnement (déterministe ou stochastique) contrôlé par un agent.

$$M = (S, A, R, T)$$

où :

- S : ensemble des **états** de l'environnement.
- A : ensemble des **actions** possibles.

Environnement ? Processus de décision markovien (MDP)

Un **processus de décision markovien (MDP)** modélise la dynamique d'un environnement (déterministe ou stochastique) contrôlé par un agent.

$$M = (S, A, R, T)$$

où :

- S : ensemble des **états** de l'environnement.
- A : ensemble des **actions** possibles.
- $R(s, a, s')$: **fonction de récompense**.

Environnement ? Processus de décision markovien (MDP)

Un **processus de décision markovien (MDP)** modélise la dynamique d'un environnement (déterministe ou stochastique) contrôlé par un agent.

$$M = (S, A, R, T)$$

où :

- S : ensemble des **états** de l'environnement.
- A : ensemble des **actions** possibles.
- $R(s, a, s')$: **fonction de récompense**.
- $T(s'|s, a)$: **fonction de transition** :
 - Cas stochastique : probabilité $T(s'|s, a)$.
 - Cas déterministe : transition directe $T(s, a) = s'$.

Environnement ? Processus de décision markovien (MDP)

Un **processus de décision markovien (MDP)** modélise la dynamique d'un environnement (déterministe ou stochastique) contrôlé par un agent.

$$M = (S, A, R, T)$$

où :

- S : ensemble des **états** de l'environnement.
- A : ensemble des **actions** possibles.
- $R(s, a, s')$: **fonction de récompense**.
- $T(s'|s, a)$: **fonction de transition**

Attention : **Si les états de l'ensemble S ne sont pas directement observables, le problème est en réalité un POMDP (Partially Observable Markov Decision Process)**

→ RL : approximer le MDP en apprenant **une politique de décision qui maximise l'espérance des récompenses futures cumulées**

- $R(s, a, s')$: **fonction de récompense**.
- $T(s'|s, a)$: **fonction de transition** :
 - Cas stochastique : probabilité $T(s'|s, a)$.
 - Cas déterministe : transition directe $T(s, a) = s'$.

RL : apprentissage d'une politique de décision

→ RL : approximer le MDP en apprenant **une politique de décision qui maximise l'espérance des récompenses futures cumulées**

- La politique π peut être : stochastique $\pi(a|s)$ ou déterministe $\pi(s) = a$
- La politique vise à maximiser le retour pondéré des récompenses futures :

$$G_t = \sum_{k=0}^{\infty} \gamma^k r_{t+k}$$

- G_t : retour à partir de l'étape t
- r_{t+k} : récompense à l'étape $t+k$
- γ : facteur d'actualisation ($\gamma = 0 \rightarrow$ myope, $\gamma \approx 1 \rightarrow$ récompenses lointaines considérées)
- La politique optimale π^* maximise l'espérance du retour :

$$\pi^*(s) = \arg \max_a \mathbb{E} [G_t \mid S_t = s, A_t = a]$$

- Choisit l'action a qui maximise l'espérance des récompenses cumulées dans chaque état s

- L'humain influence les transitions et les récompenses
- L'agent doit estimer l'état latent de l'humain
- Importance du modèle cognitif ou probabiliste de l'humain

- Q-learning / Deep Q-Networks
- Policy Gradient / PPO
- RL inverse pour modéliser les préférences humaines

- Q-Learning est un algorithme d'**apprentissage par renforcement off-policy**.
- Objectif : Apprendre une **politique optimale** π^* qui maximise la récompense cumulée.
- Il est basé sur les **équations de Bellman** pour les valeurs état-action.

Équation de Bellman pour Q-Learning

Q-optimalité

$$Q(s, a) = \mathbb{E} \left[r_{t+1} + \gamma \max_{a'} Q(s_{t+1}, a') \mid s_t = s, a_t = a \right]$$

- s : état courant
- a : action choisie
- r_{t+1} : récompense reçue
- $\gamma \in [0, 1]$: facteur de discount
- s_{t+1} : état suivant
- a' : actions possibles dans l'état suivant

Exemple de boucle d'entraînement



1. Observer l'environnement, notamment l'humain
2. Estimer l'état caché
3. Choisir action via $\pi(a|s)$
4. Recevoir utilité/reward
5. Mettre à jour la politique

Q-learning : illustration

a_i : les actions de l'agent


S_i : les états de latents des utilisateurs

Stratégie exploration-exploitation



Q-learning : illustration

$$\underbrace{\text{New } Q(s, a)}_{\text{New Q-Value}} = Q(s, a) + \underbrace{\alpha}_{\text{learning rate}} \left[\underbrace{R(s, a)}_{\text{Immediate reward}} + \underbrace{\gamma}_{\text{Discount rate}} \underbrace{\max_{a'} Q'(s', a')}_{\text{Maximum predicted reward, given new state } s' \text{ and all its possible actions } a'} - Q(s, a) \right]$$



Algorithme Q-Learning

1. Initialiser $Q(s, a)$ arbitrairement pour tous s, a .
2. Pour chaque épisode :
 - Observer l'état s_t
 - Choisir une action a_t (ex: ϵ -greedy)
 - Exécuter a_t , observer r_{t+1} et s_{t+1}
 - Mettre à jour Q :
$$Q(s_t, a_t) \leftarrow Q(s_t, a_t) + \alpha \left[r_{t+1} + \gamma \max_{a'} Q(s_{t+1}, a') - Q(s_t, a_t) \right]$$
 - Passer à s_{t+1}
3. Répéter jusqu'à convergence.

- Q converge vers Q^* si chaque action est suffisamment explorée et α décroît correctement.
- $\max_{a'} Q(s_{t+1}, a')$ correspond à l'application de l'équation de Bellman.
- Q-Learning est **off-policy** : il peut apprendre la meilleure politique même en suivant une autre politique exploratoire.

- Performances sur la tâche
- Satisfaction utilisateur
- Robustesse et stabilité de l'agent

**Exercice : réfléchir à une tâche de
décision AI-Humain, modélisable
dans un cadre RL (20 minutes)**

- L'agent doit adapter ses actions à l'humain
- L'humain fournit un environnement partiellement observable
- Objectif : maximiser l'utilité globale de la tâche

Exemple : la recommandation d'activités d'apprentissage (formation)

Le problème de la décision de la prochaine activité d'apprentissage est formalisé sous la forme d'un MDP (S, A, T, R) , où :



- S est l'ensemble des *états* de connaissances de l'apprenant
- A l'ensemble des *activités d'apprentissage*
- $T : S \times A \times S \rightarrow [0, 1]$ est la *fonction de transition*, qui donne la probabilité de passer à un état s' après avoir exécuté une action a dans un état s ;
- $R : S \times A \rightarrow \mathbb{R}$ est la *fonction de récompense*, qui évalue le gain d'apprentissage associé à l'exécution de l'action a dans l'état s .

Les états de l'ensemble S n'étant pas directement observables, le problème est en réalité un **POMDP** (*Partially Observable Markov Decision Process*)

Décision des activités d'apprentissage : Modélisation de l'apprenant

L'apprenant (environnement) est modélisé avec un Bayesian Knowledge Tracing - BKT (Anderson et al. 1995; Yudelson et al. 2013)

- Un modèle de Markov caché à deux états qui permet d'inférer si un apprenant maîtrise ou non une composante de connaissance
- Quatre paramètres : L_0 (probabilité initiale de maîtrise), T (probabilité d'apprentissage), S (*slip*) et G (*guess*).



Décision des activités d'apprentissage : Apports de l'expertise humaine

- Modélisation du domaine pour réduire le problème de **l'explosion du nombre d'états latents** de l'apprenant (la malédiction de la dimensionnalité ou *curse of dimensionality*)
- Définition de la fonction de récompense pour **maximiser l'apprentissage**
- Réduire le **problème de démarrage à froid** du RL
- Aider aux déploiement de **politiques comportementales** dans le cadre du *offline* RL


Décision des activités d'apprentissage : Apports de l'expertise humaine

Réduction de l'espace des états du MDP : Modélisation du domaine (Yessad 2022; Yessad 2023)

- Identifier les composantes de connaissances (KC)
- Identifier les liens de prérequis/précédence entre les KC


→ **Structure de compétences** (espace d'états) plus réduite : $N \leq |S| \leq 3 * 2^{N-2}$

- Ne pas considérer des états improbables ou impossibles
- Améliore l'efficacité d'échantillonnage (Sampling efficiency)



Décision des activités d'apprentissage : Apports de l'expertise humaine

Réduction de l'espace des états du MDP : Modélisation du domaine




a	b	c	d	e	f
1	0	0	1	0	0



État improbable

Décision des activités d'apprentissage : Apports de l'expertise humaine

Réduction de l'espace des états du MDP : Modélisation du domaine



a	b	c	d	e	f
1	0	0	1	0	0



État improbable

a	b	c	d	e	f
1	1	0	1	0	0



État probable


Décision des activités d'apprentissage : Apports de l'expertise humaine

Problème du démarrage à froid du RL (Yessad 2022; Yessad 2023)

- Identifier les composantes de connaissances (KC)
- Identifier les liens de prérequis/précédence entre les KC

→ **Structure de compétences** (espace d'états) plus réduite : $N \leq |S| \leq 3 * 2^{N-2}$

- Ne pas considérer des états improbables ou impossibles
- Améliore l'efficacité d'échantillonnage (Sampling efficiency)




Utilité et récompense

- Définir une fonction utilité U liée à la tâche
- Relier l'utilité à la fonction de récompense R
- Exemple : efficacité, satisfaction de l'humain, coût cognitif

Définition de la fonction de récompense

$$R = \sum_{i=1}^n (s'_i - s_i) \cdot \mathbf{1}_{(s'_i > s_i)}$$



Définition de la récompense :

Soient deux vecteurs d'état successifs d'un utilisateur:

$$s = [s_1, s_2, \dots, s_n], \quad s' = [s'_1, s'_2, \dots, s'_n]$$

La récompense $r(s, s')$ est donnée par : $r(s, s') = \sum_{i=1}^n \mathbf{1}_{[s'_i > s_i]} \cdot (s'_i - s_i)$

- $\mathbf{1}_{[s'_i > s_i]} = 1$ si $s'_i > s_i$, 0 sinon
- Seuls les bits qui augmentent contribuent à la récompense

- RL permet une modélisation flexible
- La clé : définir correctement la fonction utilité
- Importance du modèle d'humain

References

-  Anderson, John R et al. (1995). **“Cognitive tutors: Lessons learned”**. In: *The journal of the learning sciences* 4.2, pp. 167–207.
-  Bellman, Richard (1966). **“Dynamic programming”**. In: *science* 153.3731, pp. 34–37.
-  Kawato, Mitsuho et al. (2007). **“Efficient reinforcement learning: computational theories, neuroscience and robotics”**. In: *Current opinion in neurobiology* 17.2, pp. 205–212.

-  Thorndike, Edward L (1932). **“Reinforcement and the law of effect”**. In: *The American Journal of Psychology* 44.2, pp. 212–222.
-  Yessad, Amel (2022). **“Personalizing the Sequencing of Learning Activities by Using the Q-Learning and the Bayesian Knowledge Tracing”**. In: *European Conference on Technology Enhanced Learning*. Springer, pp. 638–644.
-  — (2023). **“Using the ITS Components in Improving the Q-Learning Policy for Instructional Sequencing”**. In: *International Conference on Intelligent Tutoring Systems*. Springer, pp. 247–256.
-  Yudelso, Michael V et al. (2013). **“Individualized bayesian knowledge tracing models”**. In: *International conference on artificial intelligence in education*. Springer, pp. 171–180.